

Istanbul Teknik Universitesi

EBT 629E, Yapay Zeka

Donem Sonu Proje Raporu

Zaman Serisi Modelleri ile Hane Halki Enerji Tuketimi Tahmini

REFIT Veri Seti Uzerinde ARIMA, LSTM ve FB-Prophet Modellerinin Karsilastirmali Analizi

Grup Uyeleri

Nurullah Yıldırım (301252004)

Kadir Göksel Gündüz (301241077)

Furkan Çınar (301212001)

Mayis 2026

Ozet

Bu rapor, REFIT Akilli Ev veri setinden hane halki enerji tuketimine uygulanan dort zaman serisi tahmin yaklasiminin karsilastirmali bir incelemesini sunmaktadir. Uc Birlesik Krallik hanesinden (Ev 1, Ev 2 ve Ev 5) 22 aylık 8 saniye cozunurluklu olcumleri kullaniyoruz; verileri gunluk ortalama gucu uretecek sekilde yeniden orneklenir, ardindan 7 gunluk hareketli ortalama ile yumusatilir ve her seri yuzde 80 egitim, yuzde 20 test olacak sekilde zaman sirasinda bolunur. Uc aday modelin (ARIMA, Long Short-Term Memory (LSTM) ve FB-Prophet) yani sira saglik kontrolu olarak persistence temel modeli ($\hat{y}_t = y_{t-1}$) ekledik. ARIMA modeli ADF duraganlik testi ve AIC izgara araması ile ayarlanır, ardindan tek adım onde yuvarlanan tahmin protokolu altında calistirilir; LSTM uc katmanlı yiginlanmış RNN mimarisi kullanir; Prophet haftalik ve yillik mevsimsellik bileşenleriyle tek seferlik çok adım modunda calisir. Ev 2 de ARIMA(2, 1, 2) $R^2 = 0.876$ ve $RMSE = 48.7$ W e ulasir, ancak Diebold-Mariano testi persistence temel modeli ($R^2 = 0.873$) üzerindeki marjının istatistiksel olarak anlamlı olmadığını gösterir ($p = 0.665$). LSTM ($R^2 = 0.748$) ve Prophet ($R^2 = 0.015$) persistence e anlamlı olarak kaybeder (her ikisinde de $p < 0.001$). Aynı oruntu Ev 1 ve Ev 5 te de tekrarlanır: ARIMA dar bir farkla kazanir, ancak persistence üzerine çok az şey ekler; LSTM ve Prophet ise tutarlı olarak temel modelin altında kalir. Baslica ders, yumusatilmiş gunluk konut tuketiminin gecikme-1 otokorelasyonu tarafından domine edildiği; bu nedenle tek satirlik bir kuralın neredeyse tüm tahmin edilebilir yapıyı yakaladığıdır. Daha ağır makineler ancak daha guclu disasal girdiler veya daha ince granulariteli hedefler bu otokorelasyonu kirdiginda dogrulanir. Sabit rastgele tohum kullanılan tüm kod tabanı bu rapora eslik etmektedir.

1. Giris

1.1 Genel Bilgi ve Motivasyon

Hane halki elektrik tüketimi, modern enerji sistemlerinin merkezindeki birkaç sorunu aynı anda etkilemektedir. Sebeke işletmecisi açısından kısa ufuklu doğrulukla yapılan tahminler, yenilenebilir üretiminin dengelenmesi, yedek kapasite planlaması ve kısıtlama miktarının azaltılması için gereklidir. Tüketici açısından ise bu tahminler talep yanıtı programlarına katılımı, cihazların akıllı şekilde programlanmasını, çatı üstü PV ve batarya sistemleriyle entegrasyonun iyileştirilmesini kolaylaştırır. Avrupa genelinde akıllı sayaçların hızla yayılması ve makine öğrenmesi yöntemlerinin olgunlaşması, sorunun artık trafo merkezi yerine tekil hane düzeyinde çözümlenmesini mümkün kılmaktadır.

Konut tüketiminin tahmini, toplulaştırılmış talebi tahmin etmekten yapısal olarak daha zordur. Tek bir hane ani anahtarlama olayları (su ısıtıcısı, fırın, camasır makinesi), kullanıcıya özgü programlar ve hava ile tatil etkileşimi gösteren mevsimsellik içerir. Çok sayıda haneyi ortalayarak bu gürültünün büyük bölümü sonuç sinyalinin silinir; bu nedenle sebeke düzeyinde düşük MAPE raporlanırken hane düzeyinde tahmin tamamen basarsız olabilir.

1.2 Proje Hedefleri

Bu projenin sorduğu soru hem odaklı hem de uygulamaya yöneliktir: yaygın uc zaman serisi modeli olan ARIMA, LSTM ve FB-Prophet arasında, tek bir hanenin günlük enerji tüketimini tahmin etmek için hangisi daha uygundur ve bunun ardındaki gerekçeler nelerdir? Somut olarak proje dört hedeften oluşur.

- Ham 8 saniye REFIT okumalarından model çıktılarına kadar uzanan tekrar üretilebilir bir boru hattı kurmak.
- ARIMA, LSTM ve FB-Prophet modellerini aynı veri bölme protokolu altında tek bir test ortamında karşılaştırmak.
- Model performansını MSE, RMSE, MAE ve R² metrikleriyle nicel olarak ölçmek.
- Her modelin nerede kazanıp nerede kaybettiğini incelemek ve nihai tasarıma götüren iterasyonları belgelemek.

1.3 Rapor Yapısı

Bölüm 2, REFIT veri setini ve seçilen haneyi tanıtır. Bölüm 3, on işleme boru hattı ve uc modelleme yaklaşımını detaylandırır; literatürdeki çok çeşitli karşılaştırmalardan ayrışmamızı sağlayan yuvarlanan tahmin protokolu de burada anlatılır. Bölüm 4 kesifsel veri analizini sunar. Bölüm 5 sayısal sonuçları ve görsel karşılaştırmaları sunar. Bölüm 6 bulguları, çalışmanın sınırlamalarını ve

gecerlilik tehditlerini tartisir. Bolum 7 sonuc ve ileride yapilabilecek calismalarla kapanir.


2. Veri Seti: REFIT Akilli Ev Elektrik Yuku Olcumleri

2.1 Genel Bakis

REFIT (Personalised Retrofit Decision Support Tools for UK Homes), Ekim 2013 ile Haziran 2015 arasinda Birlesik Krallik Loughborough bolgesinde toplanan boylamsal bir veri setidir. Veriler Strathclyde, Loughborough ve East Anglia Universiteleri ortakliginda EPSRC finansmaniyla uretilmis ve Creative Commons Attribution 4.0 International lisansi altinda yayinlanmistir. Yirmi hane (Ev 1 ile Ev 21 arasinda, Ev 14 atlanarak) tum hane akimi olcen bir akim klempi ve dokuz adet bireysel cihaz olcumleyici ile donatilmistir. Aktif guc, yaklasik alti ile sekiz saniyede bir Watt cinsinden orneklenmis ve tum haneler toplaminda yaklasik 1,19 milyar gozlemden olusan bir koleksiyon olusturmustur (Murray, Stankovic ve Stankovic, 2017).

2.2 Secilen Hane: Ev 2

Bu projenin test ortami olarak Ev 2 secilmistir. CSV dosyasi diskte 299 MB yer kaplar ve 22 aylık bir surede toplanan 5.733.526 zaman damgali okuma icerir. Izlenen cihazlar Buzdolabi-Dondurucu, Camasir Makinesi, Bulasik Makinesi, Televizyon, Mikrodalga, Tost Makinesi, Hi-Fi, Su Isitici ve Firin Aspiratorudur. Ev 2; belgelenmis cihaz degisikligi olmamasi, cati ustü PV girisimi bulunmaması ve tipik bir Birlesik Krallik hanesinin cihaz karisimini temsil etmesi nedeniyle secilmistir.




Sekil 1. Ev 2 hanesinde toplam guc kanali ile dokuz bireysel cihaz olcumleyici arasindaki Pearson korelasyonu.

2.3 Veri Kalitesi ve Temizleme

REFIT surumu, kısa bosluklarda ileri doldurma uygular ve iki dakikadan uzun bosluklari sifirlar. Cihaz kanallarinda 4000 W uzerindeki okumalar (sensor menziline disinda) orijinal bakimcilar tarafından zaten kaldirilmistir. Bizim ek temizleme adimlarimiz, negatif toplam okumalari (klemp polarite hatalarindan kaynaklanan) kaldirir ve degerlerin ust yuzde 1 lik dilimini aykiri olarak budar. Bu adimlardan sonra toplam seri sureklidir ve yeniden ornekleme icin hazirdir.

3. Yontem



Sekil 2. Uctan uca makine ogrenmesi boru hatti. Ham 8 saniye REFIT verisi aykiri deger temizleme, gunluk yeniden orneklem ve 7 gunluk yumusatma adimlarindan gecer, ardindan uc rakip modeli besler. Modellerin tahminleri ayrilmis test seti uzerinde degerlendirilir.

3.1 Veri On Isleme

Bes on isleme adimi ham sinyali modellemeye hazirlar. Once, zaman damgasi sutunu pandas DatetimeIndex e cevrilir. Ikinci olarak, bellek tasarrufu icin Unix epoch sutunu birakilir. Ucuncu olarak, aykiri deger filtreleme negatif degerleri ve 99 uncu persentilin uzerindeki girdileri kaldirir. Dordunculuk olarak, temizlenmis seri gunluk ortalamaya yeniden orneklenir; bu islem 5,7 milyon satiri yaklasik 630 gunluk gozleme indirir ve cihaz duzeyindeki anahtarlama gurultusunun cogunu temizler. Besinci olarak, ortalanmis 7 gunluk hareketli ortalama, hafta-ici degiskenligi bastirirken haftalik ve mevsimsel donguleri korur.

Hareketli ortalamamin NaN urettigi eksik gunler, veri seti zaman sirasiyla bolunmeden once ileri ve geri doldurma ile tamamlanir. Bolme ilk yuzde 80 i egitim, son yuzde 20 yi test olarak ayirir; bu, mevsimsel kayma iceren zaman serileri icin standart protokoldur.

3.2 ARIMA Modeli


ARIMA(p, d, q), istatistiksel zaman serisi tahmininin temel modelidir. Box-Jenkins prosedurunu izledik. Augmented Dickey-Fuller testi eğitim setinde 0.94 p-değerine sahip olarak duragansizliga isaret etti; bu nedenle birinci dereceden farklılaştırma ($d = 1$) uygulandı. Ardından p in $[0, 2]$ ve q in $[0, 2]$ üzerinde izgara araması yapılarak en düşük AIC değerine sahip yapılanma seçildi: ARIMA(2, 1, 2), AIC = 4547.63.

Yuvarlanan tahmin protokolü. Nihai ARIMA modeli yuvarlanan tek-adim-onde tahmin protokolünde çalıştırılır: her test gününde model, o ana kadar gözlenen tüm veriler üzerinde yeniden uydurulur ve sadece bir sonraki gün için tahmin yapar. Bu, bir operatörün modelden üretimde nasıl yararlanacağını birebir yansıtır; çünkü dünyanın gerçek ölçümü bugünün tahmininden önce her zaman elimizdedir.

3.3 LSTM Modeli

LSTM modeli, sırasıyla 128, 64 ve 32 hücreli üç katmanlı yığınlanmış tekrarlayan ağıdır; katmanlar arasında 0.2 oranında dropout, en üstte ise 16 hücreli ReLU yoğun katman ve ardından doğrusal çıkış bulunur. Girdiler, 14 günlük kayar pencerelere uygulanan Min-Max ölçekli güç değerleridir. Eğitimde Adam iyileştirici, MSE kayıp fonksiyonu, 16 yığın büyüklüğü ve 100 epoch kullanıldı; 5 epoch boyunca doğrulama kaybında iyileşme olmazsa eğitim erken durdurulur. Sabit rastgele tohum (42), çalışmanın makineler arası tekrar üretilebilir olmasını sağlar.

LSTM Architecture for Daily Household Load Forecasting




Sekil 3. Bu projede kullanılan LSTM aginin mimarisi, hiperparametreleri ve eğitim yapılandırması.

3.4 FB-Prophet Modeli

FB-Prophet, bir seriyi trend, mevsimsellik ve tatil etkilerine ayırır ve her bileşeni ek (veya carpan) sinyal olarak uydurur. Haftalık ve yıllık mevsimselliği etkinleştirdik, günlük mevsimselliği devre dışı bıraktık (günlük yeniden örnekleme sonrasında anlamsızdır) ve carpan modu kullandık; çünkü mevsimsel salınım genliği genel düzeyle ölçeklenir. Değişim noktası onsel ölçeği varsayılan 0.05 te bırakıldı.

Cok-adim protokolu. Önemli olan, Prophet in tek seferlik çok-adım modunda çalıştırılmasıdır: yani test ufkunun tamamını (122 gün) bir kerede tahmin eder ve test seti gerçek değerlerine erişemez. Bu, Prophet in pratikteki kanonik kullanımıdır, ancak ARIMA ve LSTM in yuvarlanan kurulumlarına kıyasla onu yapışal olarak dezavantajlı kılar. Tartışmada bu noktaya geri döneceğiz.



Sekil 4. İki tahmin protokolünün karşılaştırması. ARIMA ve LSTM her tahmin öncesinde bir önceki günün gerçek değerini görür; Prophet ise yalnızca eğitim verisine dayanarak test ufkunun tamamına taahhut eder.

3.5 Persistence Temel Modeli

Karmasik bir modelin gerçekten faydalı olduğunu iddia etmeden önce, en basit alternatifi yenebildiğini göstermemiz gerekir. Bu nedenle, bir sonraki günün bir önceki günün gerçek değerine eşit olduğu tahminini ($\hat{y}_t = y_{t-1}$) üretmesi için persistence (yapışkanlık) temel modeli ekledik. Bu, zaman serisi tahmininde kanonik bir sağlık kontrolü modelidir. Persistence'i yenemeyen herhangi bir model, tek satırlık bir kuralın yakaladığından fazla bir şey öğrenmemiş demektir. Persistence, ARIMA ve LSTM ile aynı yuvarlanan protokol altında çalışır: bir sonraki günü tahmin ederken bir önceki günün gerçek değeri her zaman elimizdedir.

3.6 Değerlendirme Metrikleri

Tahmin doğruluğu birbirini tamamlayan dört metrikle ölçülür. Ortalama Kare-sel Hata (MSE) ve Karekok Ortalama Karesel Hata (RMSE) büyük hataları ağır biçimde cezalandırır; RMSE özgün birim olan Watt cinsinden raporlanır. Ortalama Mutlak Hata (MAE) aykırı değerlere daha dayanıklıdır ve yine Watt


cinsindendir. Belirleme katsayisi (R^2), aciklanan varyansin birimsiz olcumudur; 1 mukemmel tahmini, ortalama temel modelinin altinda kalan modeller icin negatif degerleri ifade eder.

3.7 Diebold-Mariano Testi ile Istatistiksel Anlamlilik

RMSE veya R^2 nin noktasal degerleri, bir modelin digerinden gercekten daha iyi olup olmadigini gizleyebilir. Bu nedenle Harvey-Leybourne-Newbold kucuk orneklem duzeltmesiyle Diebold-Mariano (DM) esit tahmin dogrulugu testini kullaniyoruz. Bos hipotez, iki rakip modelin beklenen karesel hata kaybinin esit oldugudur; negatif DM istatistigi birinci modeli, pozitif olan ikinci modeli destekler. Ilgilenilen tum ikili karsilastirmalar icin iki taraflı p-degerlerini raporluyoruz.

4. Kesifsel Veri Analizi

Modellemeden once, temizlenmis toplam sinyali zaman yapisini karakterize etmek icin inceledik. Sekil 5 teki dort panel bu analizi ozetler.



Sekil 5. Ev 2 nin kesifsel analizi. Sol ust: 22 ay boyunca gunluk ortalama guc. Sag ust: ham 8 saniye verisi uzerinden hesaplanan saatlik profil (16:00 ile 20:00 arasinda yemek pisirme ve aydinlatmaya bagli

zirve goze carpiyor). Sol alt: hafta gunlerine gore ortalama gunluk guc (hafta sonlari daha yuksek). Sag alt: gunluk gucun dagilimi.

Uc bulgu one cikti. Birincisi, gunluk seri belirgin bir mevsimsel dongu sergiliyor: kis tuketimi yaza gore belirgin sekilde yuksek; bu, elektrikli ısıtma kullanımıyla uyumlu. Ikincisi, gunluk toplulastırmanın örnekleme çokertmemesi için ham veriden hesaplanan saatlik profil, Birleşik Krallık hanelerine özgü klasik iki tepeli şekli gösteriyor: küçük bir sabah tepesi ve 16:00 ile 20:00 arasında belirgin bir akşam tepesi. Üçüncüsü, hafta-icine kıyasla hafta sonu tüketiminin yaklaşık yüzde 15 daha yüksek olması, gün içindeki dolu süre uzunluğuyla orustugu konutu yansitıyor.


5. Sonuclar

5.1 Nihai Performans Karsilastirmasi

Tablo 1, Ev 2 üzerinde persistence temel modeli ile üç adayın test seti metriklerini raporlar. Başlık sonuc: ARIMA(2, 1, 2) $R^2 = 0.876$ ile kazanan, ancak önemsiz persistence temel modelini ($R^2 = 0.873$) yenmesi üçüncü ondalık basamakta. LSTM ($R^2 = 0.748$) ve FB-Prophet ($R^2 = 0.015$) ikisi de persistence in altında kalır. Sonucu, Bölüm 5.5 te Diebold-Mariano testi ile ayrıntılı olarak inceleyeceğiz, ama sezgisel çıkarım şu: günlük konut enerjisindeki gecikme-1 otokorelasyonu bütün işi yapıyor; ARIMA bunu temiz biçimde yakalarken, LSTM ve Prophet bu yapıyı kuramıyor.

Tablo 1. Ev 2 günlük tahminleri için persistence temel modeli ($\hat{y}_t = y_{t-1}$) dahil dört yaklaşımın test seti performansı.


Model	MSE	RMSE (W)	MAE (W)	R2
Persistence	2,426.76	49.26	33.51	0.873
ARIMA(2,1,2)	2,370.01	48.68	32.75	0.876
LSTM	4,821.35	69.44	52.25	0.748
FB-Prophet	18,851.52	137.30	111.70	0.015



Sekil 6. Uc model arasinda dort degerlendirme metriginin yan-yana karsilastirmasi. MSE, RMSE ve MAE icin dusuk olan iyi, R2 icin yuksek olan iyi.

5.2 Tahmin Edilen ile Gercek Seri Karsilastirmasi

Sekil 7, her modelin tahminlerini ayrilan test degerleriyle birlikte cizer. ARIMA panelinde yuvarlanan yeniden uydurma sayesinde model en son gozlenen degere sabitlendigidinden gercek seri yakindan takip edilir. LSTM paneli trendi genel anlamda yakalar, ancak tepe ve diplerin keskinligini yumusatir. Prophet paneli aslinda parcali dogrusal bir taban cizgisi artiri mevsimsellik uretir; bu, ortalama olarak mantikli kalsa da gercek verideki keskin hareketleri izlemekte basarisiz olur.



Sekil 7. ARIMA, LSTM ve FB-Prophet için 122 günlük test penceresi boyunca gerçek ile tahmin edilen günlük ortalama güc kıyaslaması.


5.3 Eğitim Tanıları

Sekil 8 deki LSTM eğitim kaybı eğrisi, ilk hızlı yakınsamayı ve yaklaşık 12 epoch sonra platonun oluştuğunu gösterir; bu noktada erken durdurma tetiklenir. Doğrulama kaybı eğitim kaybını yakından izler; bu, ana sorunun asiri uyum olmadığını, modelin yumuşatılmış günlük sinyalden çıkarabileceği sınıra ulaştığını gösterir.



Sekil 8. LSTM eğitim ve doğrulama MSE kaybinin epochlara göre değişimi.


Sekil 9'daki Prophet ayrıştırması belirgin bir yıllık trendi (en yüksek tüketim kışın, en düşük tüketim yazın) ve orta seviyede haftalık dalgaları gösterir. Bu bileşenler mantıklı olup kesifsel analizle ortaya çıkar, ancak genel uyum kısa vadeli hareketler yerine uzun vadeli trendin etkisi altında kalır.



Sekil 9. Ev 2 nin eğitim bölümüne uydurulmuş FB-Prophet ayrıştırmasında altta yatan trend, haftalık mevsimsellik ve yıllık mevsimsellik bileşenleri.

5.4 Geliştirme İterasyonları

Tablo 1 deki nihai sonuçlar ilk denemede elde edilmedi. En iyi modelin R^2 sini negatif bölgeden 0.876 ya taşıyan tasarım kararlarını belgeledik. Sekil 10 uc iterasyonu özetler.



Sekil 10. Tasarimin uc iterasyonu ve bunlari test R2 sine etkisi. En cok fark yaratan degisiklik, tek seferlik cok-adimli ARIMA tahmininden yuvarlanan tek-adim-onde protokole gecis oldu.


5.5 Istatistiksel Anlamlilik: Diebold-Mariano Testi

Ev 2 uzerinde yapilan ikili Diebold-Mariano testleri Tablo 2 deki sonuclari verir. Uc bulgu one cikiyor. Birincisi, ARIMA nin Persistence uzerindeki gozle gorulen ustunlugu geleneksel hicbir seviyede istatistiksel olarak anlamlili degil ($p = 0.665$). Iki model bu test setinde pratik olarak ayirt edilemeyen tahminler uretiyor. Ikincisi, LSTM ve Prophet Persistence den anlamlili sekilde daha kotu (her ikisinde de $p < 0.001$): model karmasikligini artirmak burada dogrulugu aktif olarak zedeliyor. Ucuncusu, ARIMA LSTM ve Prophet i anlamlili olarak yener (her ikisinde $p < 0.001$); yani secenek LSTM veya Prophet ise ARIMA mantikli bir tercih, ancak tek satirlik bir gecikme-1 kurali da ayni isi yapar.

Tablo 2. Ev 2 icin Harvey-Leybourne-Newbold kucuk orneklem duzeltmesiyle Diebold-Mariano test sonuclari. $n = 123$ test gunu, iki taraflili p-degerleri.

Karsilastirma (Model 1 vs Model 2)			
	DM Istatistigi	p-degeri	Sonuc
ARIMA vs Persistence	-0.433	0.665	Anlamlili fark yok

Karsilastirma (Model 1 vs			
Model 2)	DM Istatistigi	p-degeri	Sonuc
LSTM vs Persistence	+3.936	< 0.001	Persistence anlamlı olarak iyi
Prophet vs Persistence	+7.949	< 0.001	Persistence anlamlı olarak iyi
ARIMA vs LSTM	-3.765	< 0.001	ARIMA anlamlı olarak iyi
ARIMA vs Prophet	-7.957	< 0.001	ARIMA anlamlı olarak iyi




Şekil 11. Ev 2 için Diebold-Mariano istatistikleri. Yeşil cubuklar yüzde 5 seviyesinde anlamlı ($|DM| > 1.96$), gri cubuklar anlamlı değil. ARIMA ile Persistence karşılaştırması anlamlı olmayan tek çifttir.

5.6 Hane-Asiri Doğrulama

Ev 2'deki sıra lamasının tek bir hanenin tesadufu olmadığını göstermek için tüm boru hattını Ev 1 ve Ev 5'te tekrarladık. Bu iki ev farklı kullanım düzeni ve cihaz karışımına sahip (Ev 1'de dondurucular ve kurutucu, Ev 5'te belirgin şekilde daha yüksek günlük ortalama güç bulunuyor); dolayısıyla üç evde de ayakta kalan herhangi bir sıralama tesadüfi olamaz. Tablo 3, hane başına R^2 değerlerini sunar.

Tablo 3. Üç REFIT hanesinde model başına R^2 . Persistence önemsiz temel modeldir; ARIMA her evde dar bir farkla kazanır, LSTM ve Prophet ise tutarlı şekilde Persistence'in altında kalır.

Model	Ev 1	Ev 2	Ev 5	Yargı
Persistence	0.963	0.873	0.901	Guclu temel model
ARIMA	0.976	0.876	0.905	Her evde en iyi
LSTM	0.859	0.748	0.647	Her evde Persistence altinda
FB-Prophet	-2.315	0.015	-1.186	Sik sik negatif R2



Sekil 12. Hane basina model R2 si. ARIMA ile Persistence arasindaki fark uc evde de kucuk, LSTM tutarli sekilde Persistence in altinda, Prophet Ev 1 ve Ev 5 te negatif R2 uretiyor.

İki bulgu burada vurgulanmalı. Birincisi, ARIMA ile Persistence arasındaki fark her evde küçük; yani Ev 2 sonucu sıra dışı değil. İkinci, Prophet üç evden ikisinde negatif R2 üreterek kışkırsız ortalamadan bile daha kötü tahmin ediyor; bu, tek hane bulgusundan daha güçlü bir ifade.

5.7 Hata Degerlerinin Pratik Yorumu

RMSE degerleri, alan birimlerine cevrildiginde daha kolay anlasilir. Ev 2 icin ortalama test tuketimi 434.8 W, yani ARIMA nin 48.7 W luk RMSE si tipik gunluk seviyenin yaklasik yuzde 11.2 sine denk gelir. Enerji cinsine cevrildiginde, 24 saat boyunca surdurulen 48.7 W luk ortalama-guc hatasi yaklasik 1.17 kWh/gun eder. Birlesik Krallik 2025 konut elektrik birim fiyati yaklasik 0.27 GBP/kWh oldugunda, bu tek hane icin yaklasik 0.32 GBP/gun beklenen faturalama hatasi anlamina gelir; aylık yaklasik 10 GBP. Toplulastirilmis bir bilanço ortamında

gun-onceki dengesizlik 0.10 GBP/kWh fiyatlandırıldığında maliyet yaklaşık 0.12 GBP/gun e duser. Bu sayılar hane basına küçük olsa da portfoy büyüklüğü ile dogrusal olarak ölçeklenir.

6. Tartisma

6.1 Persistence Sonucu ve Bize Soyledigi

Bu calismanin en önemli bulgusu ARIMA nin diğer modelleri yenmesi değil, ARIMA nin persistence i ancak düz düz yenmesi ve farkın istatistiksel olarak anlamlı olmamasıdır. Persistence yarının bugüne esit olduğunu tahmin eder: hiçbir öğrenilmiş parametresi olmayan tek satırlık bir kural. Ev 2 de $R^2 = 0.873$ e ulaşılıyor, ARIMA nin 0.876 sindan sadece 0.003 düşük. Diebold-Mariano testi ($p = 0.665$) iki modelin karesel hata kayıplarının ayırt edilemez olduğunu doğrular. Hane-asiri sonuçlar aynı resmi cizer: ARIMA nin Persistence üzerindeki R^2 farkı Ev 1 de 0.013, Ev 5 te 0.004.

Mekanik neden, 7 günlük yumusatılmış günlük tüketiminin güçlü gecikme-1 otokorelasyonudur. Dun bugunu mükemmel şekilde tahmin eder ve dunu dogrudan kullanan herhangi bir model neredeyse aynı performansı gösterir. ARIMA(2, 1, 2) iki gecikme daha ve iki hareketli-ortalama terimi ekler, ancak ek bilgi gecikme-1 e kıyasla küçüktür. Pratik sonuç net: bu granulariteye ve bu sinyal üzerinde, tek satırlık bir kural zaten oraddatahmin edilebilir yapıyı yakalıyorken ağır makineler kullanmayın.

6.2 LSTM Neden Onemsiz Temel Modelden de Düşük Performans Gösterdi

LSTM yalnızca ARIMA ya kaybetmiyor, Persistence e karşı da anlamlı şekilde kaybediyor (Ev 2 de $p < 0.001$, diğer iki evde benzer oruntu). Bu daha ağır bir sonuç: 128.929 parametrelili sınır ağı, yarının bugüne esit olacağını tahmin etmekten daha kötü. Eğitim seti 490 günlük gözlemden oluşur ve 14 günlük geriye bakış ile yalnızca 476 girdi dizisi verir. Bu kadar az veriyle ağı asiri kapasiteye sahip; yumusak ortalama davranışı öğreniyor ve Persistence in tanım gereği yakaladığı günden güne hareketleri asiri yumusatıyor. Son dönem çalışmalar (Gasparin ve diğerleri, 2024) benzer oruntuyu belgeler: altı aydan kısa eğitim verisinde basit temel modeller derin modelleri geride bırakır. Bizim verimiz daha uzun, ancak yumusatılmış günlük sinyal hala derin öğrenmenin net olarak negatif olduğu bölgede görünüyor.

6.3 Prophet Neden En Düşük Skoru Aldı

Prophet in Ev 2 deki sıfır civarındaki R^2 si zaten cesaret kırıcı değildi. Hane-asiri dogrulama resmi daha da kötulestiriyor: Ev 1 de $R^2 = -2.315$ ve Ev 5 te $R^2 = -1.186$, yani Prophet kosulsuz eğitim ortalamasından önemli ölçüde daha kötü tahmin ediyor. İki etken devrededir. Birincisi, Prophet tüm test ufkunu test seti

gerçek degerlerine erismeden tek seferde tahmin eder; bu, yuvarlanan Persistence, ARIMA ve LSTM kurulumlarına kıyasla onu yapısal olarak dezavantajlı bırakır. İkincisi, Prophet in guclu yani yavas mevsimsel trendleri ve takvim etkilerini yakalamaktır; yumusatılmış günlük konut verisindeki baskın sinyal bir önceki gün olup Prophet in ayırtmasının hedeflemediği bileşendir. Adil bir karşılaştırma Prophet i yuvarlanan yeniden uydurma modunda çalıştırmayı gerektirir, ancak veri karakteriyle yapısal uyumsuzluk yine kalır.

6.4 Kisitlamalar ve Gecerlilik Tehditleri

Uc kisitlama sonuclarimizi nitelendirir.

- Yirmi degil, uc hane. Hane-asiri dogrulama orijinal tek-hane bulgusunu guclendirir, ancak kalan 17 REFIT evini henuz test etmiyor.
- Tek degiskenli kurulum. Modellerin hicbiri hava, takvim veya cihaz duzeyinde disasal veri almaz. Bunlari eklenmesi tabloyu, ozellikle daha zengin girdileri emmek icin tasarlanan LSTM lehine, degistirebilir.
- Agir yumusatma. 7 günlük hareketli ortalama yuksek frekansli icerigi ortadan kaldirir. Gunluk rampa bilgisine ihtiyac duyan bir operasyonel tahminci icin bu secim yeniden gozden gecirilmelidir; persistence avantajı daha ince zaman olceklerinde kuculebilir.

6.5 Referans Literatur ile Karsilastirma

Burada gozlemlenen ARIMA, LSTM ve Prophet siralamasi, Buluc, Seveli ve Yunlu (2025) un Istanbul gunes uretim verisinde benzer yuvarlanan protokol altinda raporladigi ($R^2 = 0.97$) ARIMA performansiyla ortusur. Demirtop ve Seveli (2024) un LSTM in ARIMA yi gectigi ruzgar hizi calismasindan ise ayirisir; en olasi neden o calismada cok yillik saatlik verinin kullanilmis olmasidir. CNN-LSTM-Transformer (Limouni ve digerleri, 2023) ve STL-Prophet-LSTM (Xie ve digerleri, 2022) gibi hibrit modeller bileşenlerinden tutarli sekilde daha iyi sonuc verir ve burada karsilastirilan tek-model temellerinin dogal sonraki adimini olusturur.

7. Sonuc ve Gelecek Calismalar

Persistence temel modeli dahil dort yontem kullanilarak uc Birlesik Krallik hanesinin günlük ortalama gucunu tahmin eden tekrar uretilebilir bir boru hattı kurduk. Yuvarlanan tek-adim-onde protokol ve sabit rastgele tohum altinda, ARIMA(2, 1, 2) her evde en iyi model oldu, ancak tek satirlik persistence kurallı uzerindeki marji istatistiksel olarak anlamlı degildi (Ev 2 de Diebold-Mariano $p = 0.665$ ve Ev 1 ile Ev 5 te benzer kucuk farklar). LSTM ve FB-Prophet uc ortamin tumunde persistence e anlamlı olarak kaybettir; Prophet uc evden ikisinde negatif R^2 uretti. Cikardigimiz ders, bu granulariteye konut günlük enerjisinin gecikme-1 otokorelasyonu tarafından domine edildiği ve onemsiz temel modelin

uzerine model kapasitesi eklemenin olculebilir kazanc saglamadigi (ARIMA) veya aktif olarak zararli oldugu (LSTM, Prophet) yonundedir.

Metodolojik ders de en az ayni kadar onemli: yalnızca karmasik modelleri birbirine karsi raporlamak, tum model sinifinin gereksiz oldugu gercegini gizleyebilir. Persistence temel modeli ile Diebold-Mariano anlamlilik testi birlikte, temiz bir ARIMA zaferi gibi gorunen sonucu daha durust 'veri modellerin onemli olmasi icin fazla tahmin edilebilir' sonucuna donusturur.

Ilерide yapılacak calismalar icin dort yon one cikiyor.

- Gecikme-1 otokorelasyonunun daha zayif oldugu ve derin modellerin gercekten katkı sağlayabilecegi daha yuksek frekansli hedefte (saatlik veya 15 dakikalik) analizi tekrarlamak.
- Hava (sicaklik, isininim) ve takvim ozelliklerini SARIMAX ve cok degiskenli LSTM araciligiyla eklemek; bu daha agir modellere persistence in kullanamayacagi bilgiyi verir.
- Hane-asiri karsilastirmayi ucten tum 20 REFIT evine uzatmak ve hane-asiri transfer ogrenmesini keşfetmek.
- Ayristirma ve sinirsel dizi ogrenmenin guclu yanlarini birlestiren STL-Prophet-LSTM ve CNN-LSTM-Transformer gibi hibrit modeller kurmak.

Tekrarlanabilirlik Notu

Tum deneyler NumPy, Python in random modulu ve TensorFlow icin sabit rastgele tohum (42) kullanir. Veri seti, REFIT in herkese acik Kaggle aynasindan indirilir ve on isleme, egitim ve degerlendirme tek bir Python betiginde (energy_forecasting.py) kodlanir. Bu rapordaki sonuclar Python 3.13, TensorFlow 2.x, statsmodels 0.14 ve Prophet 1.3 uzerinde elde edilmistir.

Kaynakca

- [1] Atalay, B. A., and Zor, K. (2025). XGBoost ile hidroelektrik enerji tahmini. Çukurova Üniversitesi Mühendislik Fakültesi Dergisi, 40(1), 205-218.
- [2] Berus, Y., and Yakut, Y. B. (2024). Derin öğrenme (1D-CNN, RNN, LSTM, BiLSTM) ile enerji tüketim tahmini: Diyarbakır AVM örneği. Dicle University Journal of Engineering, 15(2), 311-322.
- [3] Bölüç, M., Sevil, O., and Yünlü, L. (2025). Time Series Analysis of Solar Energy Production Based on Weather Conditions. GU J Sci, Part A, 12(4), 1060-1077.
- [4] Çolak, M. B., and Özhan, E. (2025). Renewable energy forecasting in Turkey: Analytical approaches. Journal of Intelligent Systems: Theory and Applications, 8(1), 25-34.

- [5] Demirtop, A., and Seveli, O. (2024). Wind speed prediction using LSTM and ARIMA time series analysis models: A case study of Gelibolu. *Turkish Journal of Engineering*, 8(3), 524-536.
- [6] Gasparin, A., Lukovic, S., and Alippi, C. (2024). Load Forecasting for Households and Energy Communities: Are Deep Learning Models Worth the Effort? *arXiv:2501.05000*.
- [7] Limouni, T., Yaagoubi, R., Bouziane, K., Guissi, K., and Baali, E. H. (2023). Solar Energy Production Forecasting Based on a Hybrid CNN-LSTM-Transformer Model. *Mathematics*, 11(3), 676.
- [8] Murray, D., Stankovic, L., and Stankovic, V. (2017). An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study. *Scientific Data*, 4, 160122.
- [9] Rahman, M. R., and others (2025). Time-series and deep learning approaches for renewable energy forecasting in Dhaka: a comparative study of ARIMA, SARIMA, and LSTM models. *Discover Sustainability*, 6, 01733.
- [10] Sakib, N., and others (2024). Deep learning-driven hybrid model for short-term load forecasting and smart grid information management. *Scientific Reports*, 14, 63262.
- [11] Tamay, M., and Türker, G. F. (2024). Machine learning based energy forecasting for photovoltaic solar plants. *Yekarum*, 9(2), 128-146.
- [12] Triebe, O., Hewamalage, H., Pilyugina, P., Laptev, N., Bergmeir, C., and Rajagopal, R. (2021). NeuralProphet: Explainable Forecasting at Scale. *arXiv:2111.15397*.
- [13] Vargas-Forero, V. M., Manotas-Duque, D. F., and Trujillo, L. (2025). Comparative study of forecasting methods to predict the energy demand for the market of Colombia. *International Journal of Energy Economics and Policy*, 15(1), 65-76.
- [14] Xie, J., Li, Z., Zhou, Z., and Liu, S. (2022). A hybrid forecasting model using LSTM and Prophet for energy consumption with decomposition of time series data. *PeerJ Computer Science*, 8, e1001.