

Istanbul Teknik Universitesi

EBT 629E, Yapay Zeka

Donem Sonu Proje Raporu

Zaman Serisi Modelleri ile Hane Halki Enerji Tuketimi Tahmini

REFIT Veri Seti Uzerinde ARIMA, LSTM ve FB-Prophet Modellerinin Karsilastirmali Analizi

Grup Uyeleri

Nurullah Yıldırım (301252004)

Kadir Göksel Gündüz (301241077)

Furkan Çınar (301212001)

Mayıs 2026

Ozet

Bu rapor, hane halki enerji tüketimi tahmininde kullanılan uc zaman serisi modelinin karsilastirmali bir incelemesini sunmaktadır: ARIMA, Long Short-Term Memory (LSTM) ve FB-Prophet. REFIT Akilli Ev veri setindeki 2 numarali hanenin 22 aylık 8 saniye cozunurluklu olcunlerini kullanıyoruz. Veriler gunluk ortalama gucu uretecek sekilde yeniden orneklenir, ardindan 7 gunluk hareketli ortalama ile yumusatilir ve son olarak yuzde 80 egitim, yuzde 20 test olacak sekilde zaman sirasinda bolunur. ARIMA modeli ADF duraganlik testi ve AIC olcutune gore (p, d, q) izgara aramasi ile ayarlanir, ardindan tek adim onde yuvarlanan tahmin protokolu altinda calistirilir. LSTM modeli uc katmanli yiginlanmis RNN mimarisinden olusur ve erken durdurma ile 100 epoch egitilir. Prophet, haftalik ve yillik mevsimsellik bilezenleriyle tek seferlik cok adim tahmin modunda kullanilir. ARIMA en yuksek dogrulugu yakalar ($R^2 = 0.876$, RMSE = 48.7 W), LSTM ikinci sirada ($R^2 = 0.193$) ve Prophet ucuncu sirada ($R^2 = 0.015$) yer alir. ARIMA ile diger iki model arasindaki buyuk fark, kismen tahmin protokolune baglidir: ARIMA ve LSTM ogretmen zorlamasindan yararlanir, Prophet ise 122 gunluk tahmin ufkuna tek seferde baglanmak zorundadir. Sonuclar literaturde sik karsilasilan goruslerle ortusur: klasik istatistiksel modeller kisa ufuklu konut tuketimi tahmininde rekabetci kalmaya devam eder, derin ogrenmenin kazanci ise veri olcegine ve karsilastirma protokolune kosulludur. Sabit rastgele tohum kullanılan tum kod tabani bu rapora eslik etmektedir.

1. Giris

1.1 Genel Bilgi ve Motivasyon

Hane halki elektrik tüketimi, modern enerji sistemlerinin merkezindeki birkaç sorunu aynı anda etkilemektedir. Sebeke işletmecisi açısından kısa ufuklu doğrulukla yapılan tahminler, yenilenebilir üretiminin dengelenmesi, yedek kapasite planlaması ve kısıtlama miktarının azaltılması için gereklidir. Tüketici açısından ise bu tahminler talep yanıtı programlarına katılımı, cihazların akıllı şekilde programlanmasını, çatı üstü PV ve batarya sistemleriyle entegrasyonun iyileştirilmesini kolaylaştırır. Avrupa genelinde akıllı sayaçların hızla yayılması ve makine öğrenmesi yöntemlerinin olgunlaşması, sorunun artık trafo merkezi yerine tekel hane düzeyinde çözümlenmesini mümkün kılmaktadır.

Konut tüketiminin tahmini, toplulaştırılmış talebi tahmin etmekten yapısal olarak daha zordur. Tek bir hane ani anahtarlama olayları (su ısıtıcısı, fırın, camasır makinesi), kullanıcıya özgü programlar ve hava ile tatil etkileşimi gösteren mevsimsellik içerir. Çok sayıda haneyi ortalayarak bu gürültünün büyük bölümü sonuç sinyalinin silinir; bu nedenle sebeke düzeyinde düşük MAPE raporlanırken hane düzeyinde tahmin tamamen başarısız olabilir.

1.2 Proje Hedefleri

Bu projenin sorduğu soru hem odaklı hem de uygulamaya yöneliktir: yaygın uc zaman serisi modeli olan ARIMA, LSTM ve FB-Prophet arasında, tek bir hanenin günlük enerji tüketimini tahmin etmek için hangisi daha uygundur ve bunun ardındaki gerekçeler nelerdir? Somut olarak proje dört hedeften oluşur.

- Her 8 saniye REFIT okumalarından model çıktılarına kadar uzanan tekrar üretilebilir bir veri hattı kurmak.
- ARIMA, LSTM ve FB-Prophet modellerini aynı veri bölme protokolu altında tek bir test ortamında karşılaştırmak.
- Model performansını MSE, RMSE, MAE ve R² metrikleriyle nicel olarak ölçmek.
- Her modelin nerede kazanıp nerede kaybettiğini incelemek ve nihai tasarıma götüren iterasyonları belgelemek.

1.3 Rapor Yapısı

Bölüm 2, REFIT veri setini ve seçilen haneyi tanıtır. Bölüm 3, veri işleme veri hattı ve uc modelleme yaklaşımını detaylandırır; literatürdeki çok çeşitli karşılaştırmalardan ayrışmamızı sağlayan yuvarlanan tahmin protokolu de burada anlatılır. Bölüm 4 kesifsel veri analizini sunar. Bölüm 5 sayısal sonuçları ve görsel karşılaştırmaları sunar. Bölüm 6 bulguları, çalışmanın sınırlamalarını ve

gecerlilik tehditlerini tartisir. Bolum 7 sonuc ve ileride yapilabilecek calismalarla kapanir.


2. Veri Seti: REFIT Akilli Ev Elektrik Yuku Olcumleri

2.1 Genel Bakis

REFIT (Personalised Retrofit Decision Support Tools for UK Homes), Ekim 2013 ile Haziran 2015 arasinda Birlesik Krallik Loughborough bolgesinde toplanan boylamsal bir veri setidir. Veriler Strathclyde, Loughborough ve East Anglia Universiteleri ortakliginda EPSRC finansmaniyla uretilmis ve Creative Commons Attribution 4.0 International lisansi altinda yayinlanmistir. Yirmi hane (Ev 1 ile Ev 21 arasinda, Ev 14 atlanarak) tum hane akimi olcen bir akim klempi ve dokuz adet bireysel cihaz olcumleyici ile donatilmistir. Aktif guc, yaklasik alti ile sekiz saniyede bir Watt cinsinden orneklenmis ve tum haneler toplaminda yaklasik 1,19 milyar gozlemden olusan bir koleksiyon olusturmustur (Murray, Stankovic ve Stankovic, 2017).

2.2 Secilen Hane: Ev 2

Bu projenin test ortami olarak Ev 2 secilmistir. CSV dosyasi diskte 299 MB yer kaplar ve 22 aylık bir surede toplanan 5.733.526 zaman damgali okuma icerir. Izlenen cihazlar Buzdolabi-Dondurucu, Camasir Makinesi, Bulasik Makinesi, Televizyon, Mikrodalga, Tost Makinesi, Hi-Fi, Su Isitici ve Firin Aspiratorudur. Ev 2; belgelenmis cihaz degisikligi olmamasi, cati ustü PV girisimi bulunmaması ve tipik bir Birlesik Krallik hanesinin cihaz karisimini temsil etmesi nedeniyle secilmistir.




Sekil 1. Ev 2 hanesinde toplam guc kanali ile dokuz bireysel cihaz olcumleyici arasindaki Pearson korelasyonu.

2.3 Veri Kalitesi ve Temizleme

REFIT surumu, kısa bosluklarda ileri doldurma uygular ve iki dakikadan uzun bosluklari sifirlar. Cihaz kanallarinda 4000 W uzerindeki okumalar (sensor menziline disinda) orijinal bakimcilar tarafından zaten kaldirilmistir. Bizim ek temizleme adimlarimiz, negatif toplam okumalari (klemp polarite hatalarindan kaynaklanan) kaldirir ve degerlerin ust yuzde 1 lik dilimini aykiri olarak budar. Bu adimlardan sonra toplam seri sureklidir ve yeniden ornekleme icin hazirdir.

3. Yontem



Sekil 2. Uctan uca makine ogrenmesi boru hatti. Ham 8 saniye REFIT verisi aykiri deger temizleme, gunluk yeniden orneklem ve 7 gunluk yumusatma adimlarindan gecer, ardindan uc rakip modeli besler. Modellerin tahminleri ayrilmis test seti uzerinde degerlendirilir.

3.1 Veri On Isleme

Bes on isleme adimi ham sinyali modellemeye hazirlar. Once, zaman damgasi sutunu pandas DatetimeIndex e cevrilir. Ikinci olarak, bellek tasarrufu icin Unix epoch sutunu birakilir. Ucuncu olarak, aykiri deger filtreleme negatif degerleri ve 99 uncu persentilin uzerindeki girdileri kaldirir. Dordunculuk olarak, temizlenmis seri gunluk ortalamaya yeniden orneklenir; bu islem 5,7 milyon satiri yaklasik 630 gunluk gozleme indirir ve cihaz duzeyindeki anahtarlama gurultusunun cogunu temizler. Besinci olarak, ortalanmis 7 gunluk hareketli ortalama, hafta-ici degiskenligi bastirirken haftalik ve mevsimsel donguleri korur.

Hareketli ortalamamin NaN urettigi eksik gunler, veri seti zaman sirasiyla bolunmeden once ileri ve geri doldurma ile tamamlanir. Bolme ilk yuzde 80 i egitim, son yuzde 20 yi test olarak ayirir; bu, mevsimsel kayma iceren zaman serileri icin standart protokoldur.

3.2 ARIMA Modeli


ARIMA(p, d, q), istatistiksel zaman serisi tahmininin temel modelidir. Box-Jenkins prosedurunu izledik. Augmented Dickey-Fuller testi eğitim setinde 0.94 p-değerine sahip olarak duragansizliga isaret etti; bu nedenle birinci dereceden farklılaştırma ($d = 1$) uygulandı. Ardından p in $[0, 2]$ ve q in $[0, 2]$ üzerinde izgara araması yapılarak en düşük AIC değerine sahip yapılanma seçildi: ARIMA(2, 1, 2), AIC = 4547.63.

Yuvarlanan tahmin protokolü. Nihai ARIMA modeli yuvarlanan tek-adim-onde tahmin protokolünde çalıştırılır: her test gününde model, o ana kadar gözlenen tüm veriler üzerinde yeniden uydurulur ve sadece bir sonraki gün için tahmin yapar. Bu, bir operatörün modelden üretimde nasıl yararlanacağını birebir yansıtır; çünkü dünyanın gerçek ölçümü bugünün tahmininden önce her zaman elimizdedir.

3.3 LSTM Modeli

LSTM modeli, sırasıyla 128, 64 ve 32 hücreli üç katmanlı yığınlanmış tekrarlayan ağıdır; katmanlar arasında 0.2 oranında dropout, en üstte ise 16 hücreli ReLU yoğun katman ve ardından doğrusal çıkış bulunur. Girdiler, 14 günlük kayar pencerelere uygulanan Min-Max ölçekli güç değerleridir. Eğitimde Adam iyileştirici, MSE kayıp fonksiyonu, 16 yığın büyüklüğü ve 100 epoch kullanıldı; 5 epoch boyunca doğrulama kaybında iyileşme olmazsa eğitim erken durdurulur. Sabit rastgele tohum (42), çalışmanın makineler arası tekrar üretilebilir olmasını sağlar.

LSTM Architecture for Daily Household Load Forecasting




Sekil 3. Bu projede kullanılan LSTM aginin mimarisi, hiperparametreleri ve eğitim yapılandırması.

3.4 FB-Prophet Modeli

FB-Prophet, bir seriyi trend, mevsimsellik ve tatil etkilerine ayırır ve her bileşeni ek (veya carpan) sinyal olarak uydurur. Haftalık ve yıllık mevsimselliği etkinleştirdik, günlük mevsimselliği devre dışı bıraktık (günlük yeniden örnekleme sonrasında anlamsızdır) ve carpan modu kullandık; çünkü mevsimsel salınım genliği genel düzeyle ölçeklenir. Değişim noktası onsel ölçeği varsayılan 0.05 te bırakıldı.

Cok-adim protokolu. Önemli olan, Prophet in tek seferlik çok-adım modunda çalıştırılmasıdır: yani test ufkunun tamamını (122 gün) bir kerede tahmin eder ve test seti gerçek değerlerine erişemez. Bu, Prophet in pratikteki kanonik kullanımıdır, ancak ARIMA ve LSTM in yuvarlanan kurulumlarına kıyasla onu yapisal olarak dezavantajlı kılar. Tartışmada bu noktaya geri döneceğiz.




Sekil 4. İki tahmin protokolünün karsilastirmasi. ARIMA ve LSTM her tahmin oncesinde bir onceki gunun gercek degerini gorur; Prophet ise yalnızca eğitim verisine dayanarak test ufkunun tamamına taahhut eder.

3.5 Degerlendirme Metrikleri

Tahmin dogrulugu birbirini tamamlayan dort metrikle olcudur. Ortalama Kare-sel Hata (MSE) ve Karekok Ortalama Karesel Hata (RMSE) büyük hatalari agir bicimde cezalandirir; RMSE ozgun birim olan Watt cinsinden raporlanir. Ortalama Mutlak Hata (MAE) aykiri degerlere daha dayaniklidir ve yine Watt cinsindendir. Belirleme katsayisi (R^2), aciklanan varyansin birimsiz olcumudur; 1 mukemmel tahmini, ortalama temel modelinin altinda kalan modeller icin negatif degerleri ifade eder.

4. Kesifsel Veri Analizi

Modellemeden once, temizlenmis toplam sinyali zaman yapisini karakterize etmek icin inceledik. Sekil 5 teki dort panel bu analizi ozetler.



Sekil 5. Ev 2 nin kesifsel analizi. Sol ust: 22 ay boyunca gunluk ortalama guc. Sag ust: ham 8 saniye verisi uzerinden hesaplanan saatlik profil (16:00 ile 20:00 arasinda yemek pisirme ve aydinlatmaya bagli zirve goze carpiyor). Sol alt: hafta gunlerine gore ortalama gunluk guc (hafta sonlari daha yuksek). Sag alt: gunluk gucun dagilimi.

Uc bulgu one cikti. Birincisi, gunluk seri belirgin bir mevsimsel dongu sergiliyor: kis tuketimi yaza gore belirgin sekilde yuksek; bu, elektrikli ısıtma kullanımıyla uyumlu. Ikincisi, gunluk toplulastirmanin ornekleme cokertmemesi icin ham veriden hesaplanan saatlik profil, Birlesik Krallik hanelerine ozgu klasik iki tepeli sekli gosteriyor: kucuk bir sabah tepesi ve 16:00 ile 20:00 arasinda belirgin bir akşam tepesi. Ucuncusu, hafta-icine kiyasla hafta sonu tuketiminin yaklasik yuzde 15 daha yuksek olmasi, gun icindeki dolu sure uzunluguyla orustugu konutu yansitiyor.

5. Sonuclar

5.1 Nihai Performans Karsilastirmasi

Tablo 1, test seti uzerinde uc model icin elde edilen metrikleri raporlar. ARIMA dort metrigin tumunde acik bir farkla onde yer alır: $R^2 = 0.876$ ile LSTM in yaklasik dort kati, Prophet in ise yaklasik altmis kati kadar. RMSE farki daha

da carpıcıdır: ARIMA 48.7 W iken LSTM 124.2 W ve Prophet 137.3 W.

Tablo 1. Ev 2 gunluk tahminleri icin uc modelin test seti performansi.


Model	MSE	RMSE (W)	MAE (W)	R2
ARIMA(2,1,2)	2,370.01	48.68	32.75	0.876
LSTM (3-layer)	15,436.04	124.24	93.59	0.193
FB-Prophet	18,851.52	137.30	111.70	0.015



Sekil 6. Uc model arasinda dort degerlendirme metrinin yan-yana karsilastirmasi. MSE, RMSE ve MAE icin dusuk olan iyi, R2 icin yuksek olan iyi.

5.2 Tahmin Edilen ile Gercek Seri Karsilastirmasi


Sekil 7, her modelin tahminlerini ayriyan test degerleriyle birlikte cizer. ARIMA panelinde yuvarlanan yeniden uydurma sayesinde model en son gozlenen degere sabitlendiginden gercek seri yakindan takip edilir. LSTM paneli trendi genel anlamda yakalar, ancak tepe ve diplerin keskinligini yumusatir. Prophet paneli aslinda parcali dogrusal bir taban cizgisi artiri mevsimsellik uretir; bu, ortalama olarak mantikli kalsa da gercek verideki keskin hareketleri izlemekte basarisiz olur.



Sekil 7. ARIMA, LSTM ve FB-Prophet için 122 günlük test penceresi boyunca gerçek ile tahmin edilen günlük ortalama güç kıyaslaması.


5.3 Eğitim Tanıları

Sekil 8'deki LSTM eğitim kaybı eğrisi, ilk hızlı yakınsamayı ve yaklaşık 12 epoch sonra platonun oluştuğunu gösterir; bu noktada erken durdurma tetiklenir. Doğrulama kaybı eğitim kaybını yakından izler; bu, ana sorunun asiri uyum olmadığını, modelin yumuşatılmış günlük sinyalden çıkarabileceği sınıra ulaştığını gösterir.



Sekil 8. LSTM egitim ve dogrulama MSE kaybinin epoch lara gore degisimi.


Sekil 9 daki Prophet ayristirmasi belirgin bir yillik trendi (en yuksek tuketim kisin, en dusuk tuketim yazin) ve orta seviyede haftalik dongu sergiler. Bu bileşenler mantikli olup kesifsel analizle ortusur, ancak genel uyum kısa ufuklu hareketler yerine uzun ufuklu trendin etkisi altinda kalir.



Sekil 9. Ev 2 nin eğitim bölümüne uydurulmuş FB-Prophet ayrıştırmasında altta yatan trend, haftalık mevsimsellik ve yıllık mevsimsellik bileşenleri.

5.4 Geliştirme İterasyonları

Tablo 1 deki nihai sonuçlar ilk denemede elde edilmedi. En iyi modelin R^2 sini negatif bölgeden 0.876 ya taşıyan tasarım kararlarını belgeledik. Sekil 10 uc iterasyonu özetler.



Sekil 10. Tasarimin uc iterasyonu ve bunlari test R2 sine etkisi. En cok fark yaratan degisiklik, tek seferlik cok-adimli ARIMA tahmininden yuvarlanan tek-adim-onde protokole gecis oldu.

6. Tartisma

6.1 ARIMA Neden En Iyi Sonucu Verdi

ARIMA nin guclu performansi iki etkenle aciklanir. Birincisi veri karakteridir: gunluk duzeyde konut enerjisi gecikme 1 de guclu otokorelasyon gosterir, dolayisiyla bir oncesi gun bugunki tahmin icin tek basina en bilgilendirici ozelliktir. ARIMA(2, 1, 2) bu ozellige otoregresif ve hareketli ortalama terimleri uzerinden dogrudan basvurur. Ikincisi tahmin protokoludur: her adim en yeni gercek degere dayanir; bu durum, modelin parametreleri test penceresinde hafifce kayisa bile tahminleri sabit tutar.

6.2 LSTM Neden Beklenenden Dusuk Performans Gosterdi

LSTM in mutevazi skoru derin ogrenme aleyhine bir hukum degildir; veri olcegi hakkında bir yorumdur. Egitim seti 490 gunluk gozlem den olusur ve 14 gunluk geriye bakis ile birlikte yalnızca 476 girdi dizisi anlamına gelir. Yaklasik 129 bin parametreye sahip derin ogrenme mimarileri tam potansiyellerine ulasmak icin tipik olarak buyuklukler mertebesinde daha fazla orneklem ister. Sekil 8 deki egitim ve dogrulama egrileri modelin yakinsadigini ancak iyi genellestiremedigini gosterir. Son donem calismalari (Gasparin ve digerleri, 2024) benzer bir oruntuyu belgeler: alti aydan kısa egitim verisinde basit temel modeller derin modelleri

geride birakir; ancak dokuz ay veya daha uzun veriyle derin mimariler one gecmeye baslar.

6.3 Prophet Neden En Dusuk Skoru Aldi

Prophet in sifir civarindaki R^2 si dikkatli yorumlanmalidir. Iki etken devrededir. Birincisi, Prophet tum 122 gunluk ufuk icin tek seferlik cok-adim tahmin uretir ve test seti gercek degerlerine erisemez; bu, yuvarlanan ARIMA ve LSTM kurulumlarına kıyasla onu yapısal olarak dezavantajlı bırakır. Ikincisi, Prophet in guclu yani yavas mevsimsel trendleri ve takvim etkilerini yakalamaktır; her iki ogeyi de Ev 2 verisinde gormek mumkun, ancak ikisi de tuketimin baskin surukleyicisi degildir. Test seti varyansinin buyuk kismini olusturan gunden gune kalan degiskenlik, tam olarak Prophet in modellemeye calismadigi bileseendir.

Cikarim, Prophet in zayif bir model olmasi degil, karsilastirma kurallarının ogretmen zorlamasi yapabilen modelleri kayirmasidir. Bu veri seti uzerinde adil bir karsilastirma Prophet i de yuvarlanan yeniden uydurma modunda calistirmayi gerektirir; bunu yaklasik iki buyukluk mertebesinde fazla hesaplama gerektirdigi icin ileride yapılacak calismalar arasinda biraktik.

6.4 Kisitlamalar ve Gecerlilik Tehditleri

Uc kisitlama sonuclarimizi nitelendirir.

- Tek hane. Ev 2 diger 19 REFIT evini temsil etmeyebilir; farkli bir kullanim duzeni veya cihaz karisiminda sira degisebilir.
- Tek degiskenli kurulum. Modellerin hicbiri hava, takvim veya cihaz duzeyinde disasal veri almaz. Bunlarin eklenmesi farkin, ozellikle LSTM lehine, kapanmasini kolaylastiracaktir.
- Agir yumusatma. 7 gunluk hareketli ortalama yuksek frekansli icerigi ortadan kaldirir. Gunluk rampa bilgisine ihtiyac duyan bir operasyonel tahminci icin bu secim yeniden gozden gecirilmelidir.

6.5 Referans Literatur ile Karsilastirma

Burada gozlemlenen ARIMA, LSTM ve Prophet siralamasi, Buluc, Seveli ve Yunlu (2025) un Istanbul gunes uretim verisinde benzer yuvarlanan protokol altinda raporladigi ($R^2 = 0.97$) ARIMA performansıyla ortusur. Demirtop ve Seveli (2024) un LSTM in ARIMA yi gectigi ruzgar hizi calismasından ise ayrisir; en olasi neden o calismada cok yillik saatlik verinin kullanilmis olmasidir. CNN-LSTM-Transformer (Limouni ve digerleri, 2023) ve STL-Prophet-LSTM (Xie ve digerleri, 2022) gibi hibrit modeller bilesenlerinden tutarli sekilde daha iyi sonuc verir ve burada karsilastirilan tek-model temellerinin dogal sonraki adimini olusturur.

7. Sonuc ve Gelecek Calismalar

Tek bir Birlesik Krallik hanesinin gunluk ortalama gucunu tahmin eden tekrar uretilebilir bir boru hatti kurduk ve uc zaman serisi yontemini kullandik. Yuvarlanan tek-adim-onde protokol ve sabit rastgele tohum altinda, ARIMA(2, 1, 2) 122 gorulmemis gun uzerinde $R^2 = 0.876$ a ulasti; uc katmanli LSTM ($R^2 = 0.193$) ve FB-Prophet ($R^2 = 0.015$) modellerini geride birakti. Cikardigimiz dersler sunlardir: tahmin protokolu, kısa serilerde model secimini gectigi bir noktaya kadar baskindir; konut gunluk enerjisi, klasik modellerin dogal olarak yararlandigi gucludeli-1 otokorelasyon sergiler; ve derin mimariler burada elde edilenden onemli olcude fazla veri ister.

Ileride yapilacak calismalar icin dort yon one cikiyor.

- Yuvarlanan protokolu Prophet a da uygulayarak adil bir cok model karsilastirmasi yapmak.
- Hava (sicaklik, isinim) ve takvim ozelliklerini SARIMAX ve cok degiskenli LSTM araciligiyla eklemek.
- Derin ogrenme egitim maliyetini paylasmak icin 20 REFIT hanesi arasinda hane-asiri transfer ogrenmesi yapmak.
- Ayristirma ve sinirsel dizi ogrenmenin guclu yanlarini birlestiren STL-Prophet-LSTM ve CNN-LSTM-Transformer gibi hibrit modeller kurmak.

Tekrarlanabilirlik Notu

Tum deneyler NumPy, Python in random modulu ve TensorFlow icin sabit rastgele tohum (42) kullanir. Veri seti, REFIT in herkese acik Kaggle aynasindan indirilir ve on isleme, egitim ve degerlendirme tek bir Python betiginde (energy_forecasting.py) kodlanir. Bu rapordaki sonuclar Python 3.13, TensorFlow 2.x, statsmodels 0.14 ve Prophet 1.3 uzerinde elde edilmistir.

Kaynakca

- [1] Atalay, B. A., and Zor, K. (2025). XGBoost ile hidroelektrik enerji tahmini. Çukurova Üniversitesi Mühendislik Fakültesi Dergisi, 40(1), 205-218.
- [2] Berus, Y., and Yakut, Y. B. (2024). Derin öğrenme (1D-CNN, RNN, LSTM, BiLSTM) ile enerji tüketim tahmini: Diyarbakır AVM örneği. Dicle University Journal of Engineering, 15(2), 311-322.
- [3] Bölüç, M., Seveli, O., and Yünlü, L. (2025). Time Series Analysis of Solar Energy Production Based on Weather Conditions. GU J Sci, Part A, 12(4), 1060-1077.
- [4] Çolak, M. B., and Özhan, E. (2025). Renewable energy forecasting in Turkey: Analytical approaches. Journal of Intelligent Systems: Theory and Applications,

8(1), 25-34.

[5] Demirtop, A., and Seveli, O. (2024). Wind speed prediction using LSTM and ARIMA time series analysis models: A case study of Gelibolu. *Turkish Journal of Engineering*, 8(3), 524-536.

[6] Gasparin, A., Lukovic, S., and Alippi, C. (2024). Load Forecasting for Households and Energy Communities: Are Deep Learning Models Worth the Effort? *arXiv:2501.05000*.

[7] Limouni, T., Yaagoubi, R., Bouziane, K., Guissi, K., and Baali, E. H. (2023). Solar Energy Production Forecasting Based on a Hybrid CNN-LSTM-Transformer Model. *Mathematics*, 11(3), 676.

[8] Murray, D., Stankovic, L., and Stankovic, V. (2017). An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study. *Scientific Data*, 4, 160122.

[9] Rahman, M. R., and others (2025). Time-series and deep learning approaches for renewable energy forecasting in Dhaka: a comparative study of ARIMA, SARIMA, and LSTM models. *Discover Sustainability*, 6, 01733.

[10] Sakib, N., and others (2024). Deep learning-driven hybrid model for short-term load forecasting and smart grid information management. *Scientific Reports*, 14, 63262.

[11] Tamay, M., and Türker, G. F. (2024). Machine learning based energy forecasting for photovoltaic solar plants. *Yekarum*, 9(2), 128-146.

[12] Triebe, O., Hewamalage, H., Pilyugina, P., Laptev, N., Bergmeir, C., and Rajagopal, R. (2021). NeuralProphet: Explainable Forecasting at Scale. *arXiv:2111.15397*.

[13] Vargas-Forero, V. M., Manotas-Duque, D. F., and Trujillo, L. (2025). Comparative study of forecasting methods to predict the energy demand for the market of Colombia. *International Journal of Energy Economics and Policy*, 15(1), 65-76.

[14] Xie, J., Li, Z., Zhou, Z., and Liu, S. (2022). A hybrid forecasting model using LSTM and Prophet for energy consumption with decomposition of time series data. *PeerJ Computer Science*, 8, e1001.