

Dönem Sonu Proje Raporu

Zaman Serisi Modelleri ile Hane Halkı Enerji Tüketimi Tahmini

REFIT Veri Seti Üzerinde ARIMA, LSTM ve FB-Prophet Modellerinin Karşılaştırmalı Analizi

Grup Üyeleri

Nurullah Yıldırım (301252004)

Kadir Göksel Gündüz (301241077)

Furkan Çınar (301212001)

Mayıs 2026

Özet

Bu rapor, REFIT Akıllı Ev veri setinden hane halkı enerji tüketimine uygulanan dört zaman serisi tahmin yaklaşımının karşılaştırmalı bir incelemesini sunmaktadır. Üç Birleşik Krallık hanesinden (Ev 1, Ev 2 ve Ev 5) 22 aylık 8 saniye çözünürlüklü ölçümleri kullanıyoruz; verileri günlük ortalama gücü üretecek şekilde yeniden örneklenir, ardından 7 günlük hareketli ortalama ile yumuşatılır ve her seri yüzde 80 eğitim, yüzde 20 test olacak şekilde zaman sırasında bölünür. Üç aday modelin (ARIMA, Long Short-Term Memory (LSTM) ve FB-Prophet) yanı sıra sağlık kontrolü olarak persistence temel modeli ($\hat{y}_t = y_{t-1}$) ekledik. ARIMA modeli ADF durağanlık testi ve AIC ızgara araması ile ayarlanır, ardından tek adım önde yuvarlanan tahmin protokolü altında çalıştırılır; LSTM üç katmanlı yığılmış RNN mimarisi kullanır; Prophet haftalık ve yıllık mevsimsellik bileşenleriyle tek seferlik çok adım modunda çalışır. Ev 2 de ARIMA(2, 1, 2) $R^2 = 0.876$ ve $RMSE = 48.7$ W e ulaşır, ancak Diebold-Mariano testi persistence temel modeli ($R^2 = 0.873$) üzerindeki marjinin istatistiksel olarak anlamlı olmadığını gösterir ($p = 0.665$). LSTM ($R^2 = 0.748$) ve Prophet ($R^2 = 0.015$) persistence e anlamlı olarak kaybeder (her ikisinde de $p < 0.001$). Aynı örüntü Ev 1 ve Ev 5 te de tekrarlanır: ARIMA dar bir farkla kazanır, ancak persistence üzerine çok az sey ekler; LSTM ve Prophet ise tutarlı olarak temel modelin altında kalır. Baslıca ders, yumuşatılmış günlük konut tüketiminin gecikme-1 otokorelasyonu tarafından domine edildiği; bu nedenle tek satırlık bir kuralın neredeyse tüm tahmin edilebilir yapıyı yakaladığıdır. Daha ağır makineler ancak daha güçlü dışsal girdiler veya daha ince granulariteli hedefler bu otokorelasyonu kırdığında doğrulanır. Sabit rastgele tohum kullanılan tüm kod tabanı bu rapora eşlik etmektedir.

1. Giriş

1.1 Genel Bilgi ve Motivasyon

Hane halkı elektrik tüketimi, modern enerji sistemlerinin merkezindeki birkaç sorunu aynı anda etkilemektedir. Şebeke işletmecisi açısından kısa ufuklu doğrulukla yapılan tahminler, yenilenebilir üretiminin dengelenmesi, yedek kapasite planlaması ve kısıtlama miktarının azaltılması için gereklidir. Tüketici açısından ise bu tahminler talep yanıtı programlarına katılımı, cihazların akıllı şekilde programlanmasını, çatı üstü PV ve batarya sistemleriyle entegrasyonun iyileştirilmesini kolaylaştırır. Avrupa genelinde akıllı sayaçların hızla yayılması ve makine öğrenmesi yöntemlerinin olgunlaşması, sorunun artık trafo merkezi yerine tekel hane düzeyinde çalışılmasını mümkün kılmaktadır.

Konut tüketiminin tahmini, toplulastırılmış talebi tahmin etmekten yapısal olarak daha zordur. Tek bir hane ani anahtarlama olayları (su ısıtıcısı, fırın, çamaşır makinesi), kullanıcıya özgü programlar ve hava ile tatil etkileşimi

gösteren mevsimsellik içerir. Çok sayıda haneyi ortalayarak bu gürültünün büyük bölümü sonuç sinyalinin silinir; bu nedenle şebeke düzeyinde düşük MAPE raporlanırken hane düzeyinde tahmin tamamen başarısız olabilir.

1.2 Proje Hedefleri

Bu projenin sordugu soru hem odakli hem de uygulamaya yöneliktir: yaygın üç zaman serisi modeli olan ARIMA, LSTM ve FB-Prophet arasında, tek bir hanenin günlük enerji tüketimini tahmin etmek için hangisi daha uygundur ve bunun ardındaki gerekçeler nelerdir? Somut olarak proje dört hedef pesinden gider.

- Ham 8 saniye REFIT okumalarından model ciktilarina kadar uzanan tekrar üretilebilir bir boru hattı kurmak.
- ARIMA, LSTM ve FB-Prophet modellerini aynı veri bölme protokolü altında tek bir test ortamında karşılaştırmak.
- Model performansını MSE, RMSE, MAE ve R2 metrikleriyle nicel olarak ölçmek.
- Her modelin nerede kazanıp nerede kaybettiğini incelemek ve nihai tasarıma gotüren iterasyonları belgelemek.

1.3 Rapor Yapısı

Bölüm 2, REFIT veri setini ve seçilen haneyi tanıtır. Bölüm 3, ön işleme boru hattı ve üç modelleme yaklaşımını detaylandırır; literatürdeki çok çeşitli karşılaştırmalardan ayrışmamızı sağlayan yuvarlanan tahmin protokolü de burada anlatılır. Bölüm 4 keşifsel veri analizini sunar. Bölüm 5 sayısal sonuçları ve görsel karşılaştırmaları sunar. Bölüm 6 bulguları, çalışmanın sınırlamalarını ve geçerlilik tehditlerini tartışır. Bölüm 7 sonuç ve ileride yapılabilecek çalışmalarla kapanır.

2. Veri Seti: REFIT Akıllı Ev Elektrik Yüğü Ölçümleri

2.1 Genel Bakış

REFIT (Personalised Retrofit Decision Support Tools for UK Homes), Ekim 2013 ile Haziran 2015 arasında Birleşik Krallık Loughborough bölgesinde toplanan boylamsal bir veri setidir. Veriler Strathclyde, Loughborough ve East Anglia Üniversiteleri ortaklığında EPSRC finansmanı ile üretilmiş ve Creative Commons Attribution 4.0 International lisansı altında yayınlanmıştır. Yirmi hane (Ev 1 ile Ev 21 arasında, Ev 14 atlanarak) tüm hane akımı ölçen bir akım klemp ve dokuz adet bireysel cihaz ölçümleyici ile donatılmıştır. Aktif güç, yaklaşık altı ile sekiz saniyede bir Watt cinsinden örneklenmiş ve tüm haneler toplamında yaklaşık 1,19 milyar gözlemden oluşan bir koleksiyon oluşturmuştur (Murray, Stankovic ve Stankovic, 2017).

2.2 Seçilen Hane: Ev 2

Bu projenin test ortamı olarak Ev 2 seçilmiştir. CSV dosyası diskte 299 MB yer kaplar ve 22 aylık bir surede toplanan 5.733.526 zaman damgalı okuma içerir. İzlenen cihazlar Buzdolabı-Dondurucu, Çamaşır Makinesi, Bulaşık Makinesi, Televizyon, Mikrodalga, Tost Makinesi, Hi-Fi, Su Isıtıcısı ve Fırın Aspiratörüdür. Ev 2; belgelenmiş cihaz değisikliği olmaması, çatı üstü PV girişimi bulunmaması ve tipik bir Birleşik Krallık hanesinin cihaz karışımını temsil etmesi nedeniyle seçilmiştir.




Şekil 1. Ev 2 hanesinde toplam güç kanalı ile dokuz bireysel cihaz ölçümleyici arasındaki Pearson korelasyonu.

2.3 Veri Kalitesi ve Temizleme

REFIT surumu, kısa boşluklarda ileri doldurma uygular ve iki dakikadan uzun boşlukları sıfırlar. Cihaz kanallarında 4000 W üzerindeki okumalar (sensor menzilin dışında) orijinal bakımıcılar tarafından zaten kaldırılmıştır. Bizim ek temizleme adımlarımız, negatif toplam okumaları (klemp polarite hatalarından kaynaklanan) kaldırır ve değerlerin üst yüzde 1 lik dilimini aykırı olarak budar. Bu adımlardan sonra toplam seri sureklidir ve yeniden örnekleme için hazırdır.

3. Yöntem



Şekil 2. Uctan uca makine öğrenmesi boru hattı. Ham 8 saniye REFIT verisi aykırı değer temizleme, günlük yeniden örnekleme ve 7 günlük yumuşatma adımlarından geçer, ardından üç rakip modeli besler. Modellerin tahminleri ayrılmış test seti üzerinde değerlendirilir.

3.1 Veri Ön İşleme

Bes ön işleme adımı ham sinyali modellemeye hazırlar. Önce, zaman damgası sütunu pandas DatetimeIndex'e çevrilir. İkinci olarak, bellek tasarrufu için Unix epoch sütunu bırakılır. Üçüncü olarak, aykırı değer filtreleme negatif değerleri ve 99 üncü persentilin üzerindeki girdileri kaldırır. Dördüncü olarak, temizlenmiş seri günlük ortalamaya yeniden örnekleme; bu işlem 5,7 milyon satırı yaklaşık 630 günlük gözleme indirir ve cihaz düzeyindeki anahtarlama gürültüsünün cogunu temizler. Besinci olarak, ortalanmış 7 günlük hareketli ortalama, hafta-ici değişkenliği bastırırken haftalık ve mevsimsel döngüleri korur.

Hareketli ortalamanın NaN ürettiği eksik günler, veri seti zaman sırasıyla bolunmeden önce ileri ve geri doldurma ile tamamlanır. Bölme ilk yüzde 80'i eğitim, son yüzde 20'yi test olarak ayırır; bu, mevsimsel kayma içeren zaman serileri için standart protokoldür.

3.2 ARIMA Modeli

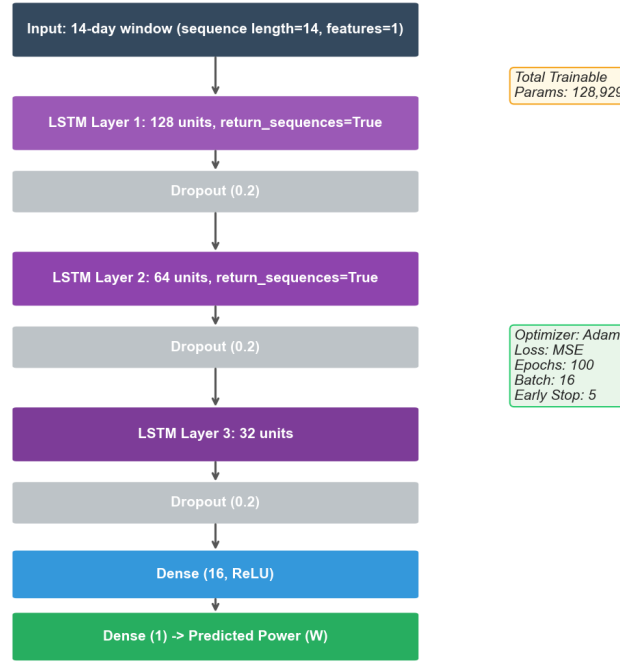
ARIMA(p, d, q), istatistiksel zaman serisi tahmininin temel modelidir. Box-Jenkins prosedürünü izledik. Augmented Dickey-Fuller testi eğitim setinde 0.94 p-değerine sahip olarak durağansızlığa işaret etti; bu nedenle birinci dereceden farklılaştırma (d = 1) uygulandı. Ardından p in [0, 2] ve q in [0, 2] üzerinde ızgara araması yapılarak en düşük AIC değerine sahip yapılandırma seçildi: ARIMA(2, 1, 2), AIC = 4547.63.

Yuvarlanan tahmin protokolü. Nihai ARIMA modeli yuvarlanan tek-adım-önde tahmin protokolünde çalıştırılır: her test gününde model, o ana kadar gözlenen tüm veriler üzerinde yeniden uydurulur ve sadece bir sonraki gün için tahmin yapar. Bu, bir operatörün modelden üretimde nasıl yararlanacağını birebir yansıtır; çünkü dünün gerçek ölçümü bugünün tahmininden önce her zaman elimizdedir.

3.3 LSTM Modeli

LSTM modeli, sırasıyla 128, 64 ve 32 hucrelili üç katmanlı yığılmış tekrarlayan ağıdır; katmanlar arasında 0.2 oranında dropout, en uste ise 16 hucrelili ReLU yoğun katman ve ardından dogrusal çıkış bulunur. Girdiler, 14 günlük kayar pencerelele uygulanan Min-Max ölçekli güç deęerleridir. Eğitimde Adam iyileştirici, MSE kayıp fonksiyonu, 16 yığın büyüklüğü ve 100 epoch kullanıldı; 5 epoch boyunca doęrulama kaybında iyileşme olmazsa eğitim erken durdurulur. Sabit rastgele tohum (42), çalışmanın makineler arası tekrar üretilebilir olmasını sağlar.

LSTM Architecture for Daily Household Load Forecasting

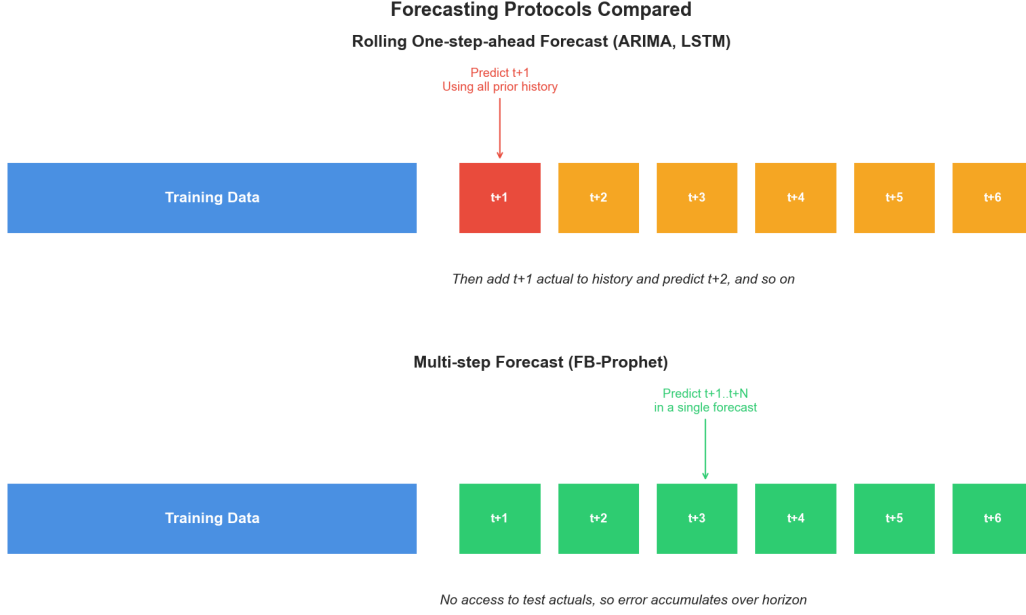


Şekil 3. Bu projede kullanılan LSTM ağıının mimarisi, hiperparametreleri ve eğitim yapılandırması.

3.4 FB-Prophet Modeli

FB-Prophet, bir seriyi trend, mevsimsellik ve tatil etkilerine ayırır ve her bileşeni ek (veya carpan) sinyal olarak uydurur. Haftalık ve yıllık mevsimsellięi etkinleştirdik, günlük mevsimsellięi devre dışı bıraktık (günlük yeniden örnekleme sonrasında anlamsızdır) ve carpan modu kullandık; çünkü mevsimsel salınım genlięi genel düzeyle ölçeklenir. Deęişim noktası onsel ölceęi varsayılan 0.05 te bırakıldı.

Çok-adım protokolü. Önemli olan, Prophet in tek seferlik çok-adım modunda çalıştırılmasıdır; yani test ufkunun tamamını (122 gün) bir kerede tahmin eder ve test seti gerçek deęerlerine erisemez. Bu, Prophet in pratikteki kanonik kullanımıdır, ancak ARIMA ve LSTM in yuvarlanan kurulumlarına kıyasla onu yapısal olarak dezavantajlı kılar. Tartismada bu noktaya geri doneceęiz.



Şekil 4. İki tahmin protokolünün karşılaştırması. ARIMA ve LSTM her tahmin öncesinde bir önceki günün gerçek değerini gorur; Prophet ise yalnızca eğitim verisine dayanarak test ufkunun tamamına taahhut eder.

3.5 Persistence Temel Modeli

Karmasik bir modelin gerçekten faydalı olduğunu iddia etmeden önce, en basit alternatifi yenebildiğini göstermemiz gerekir. Bu nedenle, bir sonraki günün bir önceki günün gerçek değerine eşit olduğu tahminini ($\hat{y}_t = y_{t-1}$) üretmesi için persistence (yapışkanlık) temel modeli ekledik. Bu, zaman serisi tahmininde kanonik bir sağlık kontrolü modelidir. Persistence'i yenemeyen herhangi bir model, tek satırlık bir kuralın yakaladığından fazla bir şey öğrenmemiş demektir. Persistence, ARIMA ve LSTM ile aynı yuvarlanan protokol altında çalışır: bir sonraki günü tahmin ederken bir önceki günün gerçek değeri her zaman elimizdedir.

3.6 Değerlendirme Metrikleri


Tahmin doğruluğu birbirini tamamlayan dört metrikle ölçülür. Ortalama Karesel Hata (MSE) ve Karekok Ortalama Karesel Hata (RMSE) büyük hataları ağır biçimde cezalandırır; RMSE özgün birim olan Watt cinsinden raporlanır. Ortalama Mutlak Hata (MAE) aykırı değerlere daha dayanıklıdır ve yine Watt cinsindendir. Belirleme katsayısı (R2), açıklanan varyansın birimsiz ölçümüdür; 1 mükemmel tahmini, ortalama temel modelinin altında kalan modeller için negatif değerleri ifade eder.

3.7 Diebold-Mariano Testi ile İstatistiksel Anlamlılık

RMSE veya R2 nin noktasal değerleri, bir modelin diğerinden gerçekten daha iyi olup olmadığını gizleyebilir. Bu nedenle Harvey-Leybourne-Newbold küçük örneklem düzeltmesiyle Diebold-Mariano (DM) eşit tahmin doğruluğu testini kullanıyoruz. Bos hipotez, iki rakip modelin beklenen karesel hata kaybının eşit olduğudur; negatif DM istatistigi birinci modeli, pozitif olan ikinci modeli destekler. İlgiilenilen tüm ikili karşılaştırmalar için iki taraflı p-değerlerini raporluyoruz.

4. Keşifsel Veri Analizi

Modellemeden önce, temizlenmiş toplam sinyali zaman yapısını karakterize etmek için inceledik. Şekil 5 teki dört panel bu analizi özetler.



Şekil 5. Ev 2'nin keşifsel analizi. Sol üst: 22 ay boyunca günlük ortalama güç. Sağ üst: ham 8 saniye verisi üzerinden hesaplanan saatlik profil (16:00 ile 20:00 arasında yemek pişirme ve aydınlatmaya bağlı zirve göze carıyor). Sol alt: hafta günlerine göre ortalama günlük güç (hafta sonları daha yüksek). Sağ alt: günlük gücün dağılımı.

Üç bulgu öne çıktı. Birincisi, günlük seri belirgin bir mevsimsel doku sergiliyor: kis tüketimi yaza göre belirgin şekilde yüksek; bu, elektrikli ısıtma kullanımıyla uyumlu. İkincisi, günlük toplulaştırmanın örnekleme sıklığına göre belirgin bir sabah tepesi ve 16:00 ile 20:00 arasında belirgin bir akşam tepesi. Üçüncüsü, hafta-icine kıyasla hafta sonu tüketiminin yaklaşık yüzde 15 daha yüksek olması, gün içindeki dolu süre uzunluğuyla orantılı olarak yansıtıyor.


5. Sonuçlar

5.1 Nihai Performans Karşılaştırması

Tablo 1, Ev 2 üzerinde persistence temel modeli ile üç adayın test seti metriklerini raporlar. Başlık sonucu: ARIMA(2, 1, 2) $R^2 = 0.876$ ile kazanan, ancak önemsiz persistence temel modelini ($R^2 = 0.873$) yenmesi ucuncu ondalık basamakta. LSTM ($R^2 = 0.748$) ve FB-Prophet ($R^2 = 0.015$) ikisi de persistence in altında kalır. Sonucu, Bölüm 5.5'te Diebold-Mariano testi ile ayrıntılı olarak inceleyeceğiz, ama sezgisel çıkarım şu: günlük konut enerjisindeki gecikme-1 otokorelasyonu bütün ısı yapıyor; ARIMA bunu temiz biçimde yakalarken, LSTM ve Prophet bu yapıyı kuramıyor.

Tablo 1. Ev 2 günlük tahminleri için persistence temel modeli ($\hat{y}_t = y_{t-1}$) dahil dört yaklaşımın test seti performansı.


Model	MSE	RMSE (W)	MAE (W)	R2
Persistence	2,426.76	49.26	33.51	0.873
ARIMA(2,1,2)	2,370.01	48.68	32.75	0.876
LSTM (3-layer)	4,821.35	69.44	52.25	0.748
FB-Prophet	18,851.52	137.30	111.70	0.015



Şekil 6. Üç model arasında dört değerlendirme metrinin yan-yan karşılaştırması. MSE, RMSE ve MAE için düşük olan iyi, R2 için yüksek olan iyi.

5.2 Tahmin Edilen ile Gerçek Seri Karşılaştırması


Şekil 7, her modelin tahminlerini ayrılan test degerleriyle birlikte cizer. ARIMA panelinde yuvarlanan yeniden uyurma sayesinde model en son gozlenen degere sabitlendigidinden gercek seri yakindan takip edilir. LSTM paneli trendi genel anlamda yakalar, ancak tepe ve diplerin keskinligini yumusatir. Prophet paneli aslında parcali dogrusal bir taban çizgisi artırır mevsimsellik üretir; bu, ortalama olarak mantıklı kalsa da gercek verideki keskin hareketleri izlemekte başarısız olur.



Şekil 7. ARIMA, LSTM ve FB-Prophet için 122 günlük test penceresi boyunca gerçek ile tahmin edilen günlük ortalama güç kıyaslaması.


5.3 Eğitim Tanıları

Şekil 8 deki LSTM eğitim kaybı eğrisi, ilk hızlı yakınsamayı ve yaklaşık 12 epoch sonra platonun oluştuğunu gösterir; bu noktada erken durdurma tetiklenir. Doğrulama kaybı eğitim kaybını yakından izler; bu, ana sorunun aşırı uyum olmadığını, modelin yumuşatılmış günlük sinyalden çıkarabileceği sinira ulaştığını gösterir.



Şekil 8. LSTM eğitim ve doğrulama MSE kaybının epoch lara göre değişimi.

Şekil 9 daki Prophet ayrıştırması belirgin bir yıllık trendi (en yüksek tüketim kışın, en düşük tüketim yazın) ve orta seviyede haftalık dalgı sergiler. Bu bileşenler mantıklı olup keşifsel analizle örtüşür, ancak genel uyum kısa ufuklu hareketler yerine uzun ufuklu trendin etkisi altında kalır.

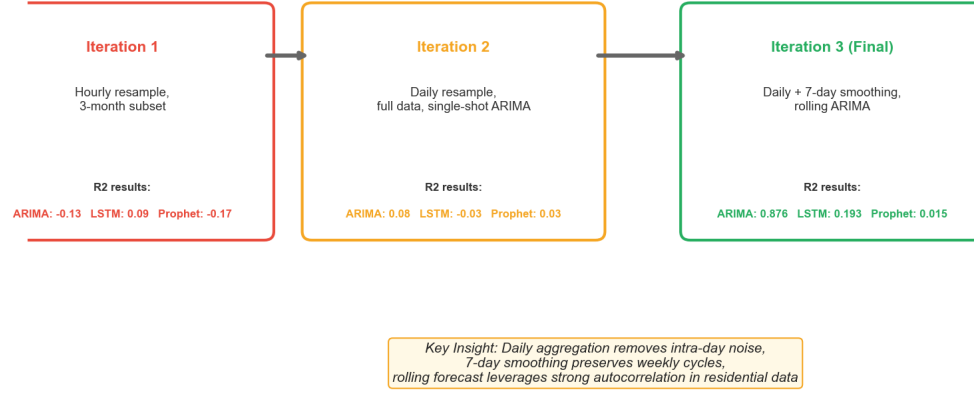


Şekil 9. Ev 2 nin eğitim bölümüne uydurulmuş FB-Prophet ayrıştırmasında altta yatan trend, haftalık mevsimsellik ve yıllık mevsimsellik bileşenleri.

5.4 Geliştirme İterasyonları

Tablo 1 deki nihai sonuçlar ilk denemede elde edilmedi. En iyi modelin R2 sini negatif bolgeden 0.876 ya taşıyan tasarım kararlarını belgeledik. Şekil 10 üç iterasyonu özetler.

Development Iterations: From -0.13 to 0.876 R2




Şekil 10. Tasarımın üç iterasyonu ve bunların test R2 sine etkisi. En çok fark yaratan değişiklik, tek seferlik çok-adımlı ARIMA tahmininden yuvarlanan tek-adım-önde protokole geçiş oldu.

5.5 İstatistiksel Anlamlılık: Diebold-Mariano Testi

Ev 2 üzerinde yapılan ikili Diebold-Mariano testleri Tablo 2'deki sonuçları verir. Üç bulgu öne çıkıyor. Birincisi, ARIMA'nın Persistence üzerindeki gözle görülen üstünlüğü geleneksel hiçbir seviyede istatistiksel olarak anlamlı değil ($p = 0.665$). İki model bu test setinde pratik olarak ayırt edilemeyen tahminler üretiyor. İkincisi, LSTM ve Prophet Persistence'den anlamlı şekilde daha kötü (her ikisinde de $p < 0.001$): model karmaşıklığını artırmak burada doğruluğu aktif olarak zedeliyor. Üçüncüsü, ARIMA LSTM ve Prophet'i anlamlı olarak yener (her ikisinde $p < 0.001$); yani seçenek LSTM veya Prophet ise ARIMA mantıklı bir tercih, ancak tek satırlık bir gecikme-1 kuralı da aynı işi yapar.

Tablo 2. Ev 2 için Harvey-Leybourne-Newbold küçük örneklem düzeltmesiyle Diebold-Mariano test sonuçları. $n = 123$ test günü, iki taraflı p -değerleri.

Karşılaştırma (Model 1 vs Model 2)	DM İstatistiği	p -değeri	Sonuç
ARIMA vs Persistence	-0.433	0.665	Anlamlı fark yok
LSTM vs Persistence	+3.936	< 0.001	Persistence anlamlı olarak iyi
Prophet vs Persistence	+7.949	< 0.001	Persistence anlamlı olarak iyi
ARIMA vs LSTM	-3.765	< 0.001	ARIMA anlamlı olarak iyi
ARIMA vs Prophet	-7.957	< 0.001	ARIMA anlamlı olarak iyi




Şekil 11. Ev 2 için Diebold-Mariano istatistikleri. Yeşil çubuklar yüzde 5 seviyesinde anlamlı ($|DM| > 1.96$), gri çubuklar anlamlı değil. ARIMA ile Persistence karşılaştırması anlamlı olmayan tek çifttir.

5.6 Hane-Aşırı Doğrulama

Ev 2 deki sıra lamasinin tek bir hanenin tesadufu olmadığını göstermek için tüm boru hattını Ev 1 ve Ev 5 te tekrarladık. Bu iki ev farklı kullanım düzeni ve cihaz karışımına sahip (Ev 1 de dondurucular ve kurutucu, Ev 5 te belirgin şekilde daha yüksek günlük ortalama güç bulunuyor); dolayısıyla üç evde de ayakta kalan herhangi bir sıralama tesadufi olamaz. Tablo 3, hane başına R2 değerlerini sunar.

Tablo 3. Üç REFIT hanesinde model başına R2. Persistence önemsiz temel modeldir; ARIMA her evde dar bir farkla kazanır, LSTM ve Prophet ise tutarlı şekilde Persistence in altında kalır.

Model	Ev 1	Ev 2	Ev 5	Yargı
Persistence	0.963	0.873	0.901	Güçlü temel model
ARIMA	0.976	0.876	0.905	Her evde en iyi
LSTM	0.859	0.748	0.647	Her evde Persistence altında
FB-Prophet	-2.315	0.015	-1.186	Sık sık negatif R2



Şekil 12. Hane başına model R2 si. ARIMA ile Persistence arasındaki fark üç evde de küçük, LSTM tutarlı şekilde Persistence in altında, Prophet Ev 1 ve Ev 5 te negatif R2 üretiyor.

İki bulgu burada vurgulanmalı. Birincisi, ARIMA ile Persistence arasındaki fark her evde küçük; yanı Ev 2 sonucu sıra dışı değil. İkincisi, Prophet üç evden ikisinde negatif R2 ureterek koşulsuz ortalamadan bile daha kotu tahmin ediyor; bu, tek hane bulgusundan daha güçlü bir ifade.

5.7 Hata Degerlerinin Pratik Yorumu

RMSE değerleri, alan birimlerine çevrildiğinde daha kolay anlaşılır. Ev 2 için ortalama test tüketimi 434.8 W, yanı ARIMA nin 48.7 W luk RMSE si tipik günlük seviyenin yaklaşık yüzde 11.2 sine denk gelir. Enerji cinsine çevrildiğinde, 24 saat boyunca sürdürülen 48.7 W luk ortalama-güç hatası yaklaşık 1.17 kWh/gün eder. Birleşik Krallık 2025 konut elektrik birim fiyatı yaklaşık 0.27 GBP/kWh olduğunda, bu tek hane için yaklaşık 0.32 GBP/gün beklenen faturalama hatası anlamına gelir; aylık yaklaşık 10 GBP. Toplulastirilmiş bir bilanco ortamında gün-önceki dengesizlik 0.10 GBP/kWh fiyatlandırıldığında maliyet yaklaşık 0.12 GBP/gün e duser. Bu sayılar hane başına küçük olsa da portföy büyüklüğü ile dogrusal olarak ölçeklenir.

6. Tartışma

6.1 Persistence Sonucu ve Bize Söylediği

Bu çalışmanın en önemli bulgusu ARIMA nin diğer modelleri yenmesi değil, ARIMA nin persistence i ancak düz düz yenmesi ve farkın istatistiksel olarak anlamlı olmamasıdır. Persistence yarının bugüne eşit olduğunu tahmin eder: hiçbir öğrenilmiş parametresi olmayan tek satırlık bir kural. Ev 2 de $R^2 = 0.873$ e ulasiyor, ARIMA nin 0.876 sindan sadece 0.003 düşük. Diebold-Mariano testi ($p = 0.665$) iki modelin karesel hata kayiplarının ayırt edilemez olduğunu doğrular. Hane-aşırı sonuçlar aynı resmi cizer: ARIMA nin Persistence üzerindeki R^2 farkı Ev 1 de 0.013, Ev 5 te 0.004.

Mekanik neden, 7 günlük yumuşatılmış günlük tüketiminin güçlü gecikme-1 otokorelasyonudur. Dun bugunu mükemmel şekilde tahmin eder ve dunu doğrudan kullanan herhangi bir model neredeyse aynı performansi gösterir. ARIMA(2, 1, 2) iki gecikme daha ve iki hareketli-ortalama terimi ekler, ancak ek bilgi gecikme-1 e kıyasla kucuktur. Pratik sonuç net: bu granulariteye ve bu sinyal üzerinde, tek satırlık bir kural zaten oraddatahmin edilebilir yapıyı yakalıyorken ağır makineler kullanmayın.

6.2 LSTM Neden Önemsiz Temel Modelden de Düşük Performans Gösterdi

LSTM yalnızca ARIMA ya kaybetmiyor, Persistence e karşı da anlamlı şekilde kaybediyor (Ev 2 de $p < 0.001$, diğer iki evde benzer örüntü). Bu daha ağır bir sonuç: 128.929 parametrelili sınır ağı, yarının bugüne eşit olacağını tahmin etmekten daha kotu. Eğitim seti 490 günlük gözlemden oluşur ve 14 günlük geriye bakış ile yalnızca 476 girdi dizisi verir. Bu kadar az veriyle ağı aşırı kapasiteye sahip; yumuşak ortalama davranisi öğreniyor ve Persistence in tanım gereği yakaladığı günden güne hareketleri aşırı yumuşatıyor. Son dönem çalışmaları (Gasparin ve diğerleri, 2024) benzer örüntüyü belgeler: altı aydan kısa eğitim verisinde basit temel modeller derin modelleri geride bırakır. Bizim verimiz daha uzun, ancak yumuşatılmış günlük sinyal hala derin öğrenmenin net olarak negatif olduğu bolgede görünuyor.

6.3 Prophet Neden En Düşük Skoru Aldı

Prophet in Ev 2 deki sıfır civarındaki R^2 si zaten cesaret kırıcı değildi. Hane-aşırı doğrulama resmi daha da kotulestiriyor: Ev 1 de $R^2 = -2.315$ ve Ev 5 te $R^2 = -1.186$, yanı Prophet koşulsuz eğitim ortalamasından önemli ölçüde daha kotu tahmin ediyor. İki etken devrededir. Birincisi, Prophet tüm test ufkunu test seti gerçek değerlerine erismeden tek seferde tahmin eder; bu, yuvarlanan Persistence, ARIMA ve LSTM kurulumlarına kıyasla onu yapısal olarak

dezavantajlı bırakır. İkincisi, Prophet in güçlü yanı yavas mevsimsel trendleri ve takvim etkilerini yakalamaktır; yumuşatılmış günlük konut verisindeki baskın sinyal bir önceki gün olup Prophet in ayrıştırmasının hedeflemediği bileşendir. Adil bir karşılaştırma Prophet i yuvarlanan yeniden uydurma modunda çalıştırmayı gerektirir, ancak veri karakteriyle yapısal uyumsuzluk yine kalır.

6.4 Kısıtlamalar ve Geçerlilik Tehditleri

Üç kısıtlama sonuçlarımızı nitelendirir.

- Yirmi değil, üç hane. Hane-aşırı doğrulama orijinal tek-hane bulgusunu güçlendirir, ancak kalan 17 REFIT evini henüz test etmiyor.
- Tek degiskenli kurulum. Modellerin hicbiri hava, takvim veya cihaz düzeyinde dışsal veri almaz. Bunların eklenmesi tabloyu, özellikle daha zengin girdileri emmek için tasarlanan LSTM lehine, değiştirebilir.
- Ağır yumuşatma. 7 günlük hareketli ortalama yüksek frekanslı içeriği ortadan kaldırır. Günlük rampa bilgisine ihtiyaç duyan bir operasyonel tahminci için bu seçim yeniden gözden geçirilmelidir; persistence avantajı daha ince zaman ölçeklerinde küçülebilir.

6.5 Referans Literatür ile Karşılaştırma

Burada gözlemlenen ARIMA, LSTM ve Prophet sıralaması, Buluc, Sevlı ve Yunlu (2025) un İstanbul güneş üretim verisinde benzer yuvarlanan protokol altında raporladığı ($R^2 = 0.97$) ARIMA performansı ile örtüşür. Demirtop ve Sevlı (2024) un LSTM in ARIMA yi geçtiği rüzgar hızı çalışmasından ise ayrışır; en olası neden o çalışmada çok yıllık saatlik verinin kullanılmış olmasıdır. CNN-LSTM-Transformer (Limouni ve diğerleri, 2023) ve STL-Prophet-LSTM (Xie ve diğerleri, 2022) gibi hibrit modeller bileşenlerinden tutarlı şekilde daha iyi sonuç verir ve burada karşılaştırılan tek-model temellerinin doğal sonraki adımını oluşturur.

7. Sonuç ve Gelecek Çalışmalar

Persistence temel modeli dahil dört yöntem kullanılarak üç Birleşik Krallık hanesinin günlük ortalama gücünü tahmin eden tekrar üretilebilir bir boru hattı kurduk. Yuvarlanan tek-adım-önde protokol ve sabit rastgele tohum altında, ARIMA(2, 1, 2) her evde en iyi model oldu, ancak tek satırlık persistence kuralı üzerindeki marjı istatistiksel olarak anlamlı değildi (Ev 2 de Diebold-Mariano $p = 0.665$ ve Ev 1 ile Ev 5 te benzer küçük farklar). LSTM ve FB-Prophet üç ortamın tümünde persistence e anlamlı olarak kaybetti; Prophet üç evden ikisinde negatif R^2 üretti. Çıkardığımız ders, bu granulariteye konut günlük enerjisinin gecikme-1 otokorelasyonu tarafından domine edildiği ve önemsiz temel modelin üzerine model kapasitesi eklemenin ölçülebilir kazanç sağlamadığı (ARIMA) veya aktif olarak zararlı olduğu (LSTM, Prophet) yönündedir.

Metodolojik ders de en az aynı kadar önemli: yalnızca karmaşık modelleri birbirine karşı raporlamak, tüm model sınıfının gereksiz olduğu gerçeğini gizleyebilir. Persistence temel modeli ile Diebold-Mariano anlamlılık testi birlikte, temiz bir ARIMA zaferi gibi görünen sonucu daha durust 'veri modellerin önemli olması için fazla tahmin edilebilir' sonucuna dönüştürür.

İleride yapılacak çalışmalar için dört yön öne çıkıyor.

- Gecikme-1 otokorelasyonunun daha zayıf olduğu ve derin modellerin gerçekten katkı sağlayabileceği daha yüksek frekanslı hedefte (saatlik veya 15 dakikalık) analizi tekrarlamak.
- Hava (sıcaklık, ışınım) ve takvim özelliklerini SARIMAX ve çok degiskenli LSTM aracılığıyla eklemek; bu daha ağır modellere persistence in kullanamayacağı bilgiyi verir.
- Hane-aşırı karşılaştırmayı uçtan tüm 20 REFIT evine uzatmak ve hane-aşırı transfer öğrenmesini keşfetmek.

- Ayrıştırma ve sinirsel dizi öğrenmenin güçlü yanlarını birleştiren STL-Prophet-LSTM ve CNN-LSTM-Transformer gibi hibrit modeller kurmak.

Tekrarlanabilirlik Notu

Tüm deneyler NumPy, Python in random modulu ve TensorFlow için sabit rastgele tohum (42) kullanır. Veri seti, REFIT in herkese açık Kaggle aynasından indirilir ve ön işleme, eğitim ve değerlendirme tek bir Python betiğinde (energy_forecasting.py) kodlanır. Bu rapordaki sonuçlar Python 3.13, TensorFlow 2.x, statsmodels 0.14 ve Prophet 1.3 üzerinde elde edilmiştir.

Kaynakça

- [1] Atalay, B. A., and Zor, K. (2025). XGBoost ile hidroelektrik enerji tahmini. Çukurova Üniversitesi Mühendislik Fakültesi Dergisi, 40(1), 205-218.
- [2] Berus, Y., and Yakut, Y. B. (2024). Derin öğrenme (1D-CNN, RNN, LSTM, BiLSTM) ile enerji tüketim tahmini: Diyarbakır AVM örneği. Dicle University Journal of Engineering, 15(2), 311-322.
- [3] Bölüş, M., Seveli, O., and Yünlü, L. (2025). Time Series Analysis of Solar Energy Production Based on Weather Conditions. GU J Sci, Part A, 12(4), 1060-1077.
- [4] Çolak, M. B., and Özhan, E. (2025). Renewable energy forecasting in Turkey: Analytical approaches. Journal of Intelligent Systems: Theory and Applications, 8(1), 25-34.
- [5] Demirtop, A., and Seveli, O. (2024). Wind speed prediction using LSTM and ARIMA time series analysis models: A case study of Gelibolu. Turkish Journal of Engineering, 8(3), 524-536.
- [6] Gasparin, A., Lukovic, S., and Alippi, C. (2024). Load Forecasting for Households and Energy Communities: Are Deep Learning Models Worth the Effort? arXiv:2501.05000.
- [7] Limouni, T., Yaagoubi, R., Bouziane, K., Guissi, K., and Baali, E. H. (2023). Solar Energy Production Forecasting Based on a Hybrid CNN-LSTM-Transformer Model. Mathematics, 11(3), 676.
- [8] Murray, D., Stankovic, L., and Stankovic, V. (2017). An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study. Scientific Data, 4, 160122.
- [9] Rahman, M. R., and others (2025). Time-series and deep learning approaches for renewable energy forecasting in Dhaka: a comparative study of ARIMA, SARIMA, and LSTM models. Discover Sustainability, 6, 01733.
- [10] Sakib, N., and others (2024). Deep learning-driven hybrid model for short-term load forecasting and smart grid information management. Scientific Reports, 14, 63262.
- [11] Tamay, M., and Türker, G. F. (2024). Machine learning based energy forecasting for photovoltaic solar plants. Yekarum, 9(2), 128-146.
- [12] Triebe, O., Hewamalage, H., Pilyugina, P., Laptev, N., Bergmeir, C., and Rajagopal, R. (2021). NeuralProphet: Explainable Forecasting at Scale. arXiv:2111.15397.
- [13] Vargas-Forero, V. M., Manotas-Duque, D. F., and Trujillo, L. (2025). Comparative study of forecasting methods to predict the energy demand for the market of Colombia. International Journal of Energy Economics and Policy, 15(1), 65-76.
- [14] Xie, J., Li, Z., Zhou, Z., and Liu, S. (2022). A hybrid forecasting model using LSTM and Prophet for energy consumption with decomposition of time series data. PeerJ Computer Science, 8, e1001.