

Ekip Brief, Detayli Surum

Selam,

Onceki brief'i okuduktan sonra model kısmi tam oturmamış. Çok normal, ben de ilk basta dolastım. Bu sefer **sifirdan**, günlük dilden baslıyorum. Sonunda projeyi senden iyi anlayan ben olmuyorum, sen oluyorsun. Sloganlı laflar yok, gerçek açıklamalar var.

BOLUM 1: Genel Resim

Q: Bizim projemizin amacı tam olarak neydi?

Cok kısa cevap: Bir evin yarınki elektrik tüketimini bugün tahmin etmek.

Biraz daha uzun cevap: Diyelim ki evine akıllı sayac taktirdin. Sayac saniyede bir kaç kere “su an evde X watt çekiyorsun” diye veri kaydediyor. Soru su:

Yarın sabah uyandığında evinin gün boyunca ortalama kaç watt çekeceğini *bugünden* bilebilir miyiz?

Eğer bunu bilebilirsen su işlere yarıyor: - **Sebeke işletmecisi:** Yarınki toplam talebi tahmin edip santralleri ayarlar - **Sen:** Catındaki güneş panelinden batarya doldurma saatlerini optimize edersin - **Tedarikçi:** “Yarın saat 18’de tüketim patlıyor, fiyat yükseltelim” der

Yani **enerji ekonomisinin temelinde tahmin var**. Biz bunun en küçük birimini, tek hane senaryosunu çalıştık.

Q: Niye bu proje? Hoca mı söyledi?

Hoca “ML + Enerji Sistemleri” alanında 3 proje önerisi istedi (6 Nisan). Biz üç öneri sunduk, bunlardan birini (REFIT veri seti ile zaman serisi tahmini) seçtik ve geliştirdik. Seçtiğimiz konu makaledeki çalışmanın (Buluc et al. 2025) hane bazına indirgenmiş haliydi.

Q: Makalede ne yapılmış ki bizim referansımız oldu?

Buluc ve arkadaşları İstanbul İkitelli’deki bir güneş santralinin üretimini ARIMA / LSTM / Prophet ile tahmin etmiş. ARIMA en iyiyi yapmış ($R^2=0.97$). Bizim sorumuz: **aynı uc model hane bazlı verisi için ne yapar?** Güneş santrali tahmini ile ev tahmini çok farklı, çünkü ev çok daha gürültülü.

BOLUM 2: Veri

Q: REFIT veri seti tam olarak ne?

Birleşik Krallık’ta üç üniversite (Strathclyde, Loughborough, East Anglia) Ekim 2013 - Haziran 2015 arasında 20 evi izlemiş. Her eve: - 1 **toplam sayac** (eve giren toplam akım) - 9 **bireysel cihaz monitörü** (buzdolabı, camasır makinesi, su ısıtıcısı, vs.)

her 8 saniyede bir watt cinsinden okuma yapmışlar. **Toplam yaklaşık 1.2 milyar veri noktası.**

Veriyi çıkartıp publish etmişler, Creative Commons lisanslı ücretsiz indirilebilir. Kaggle aynasından indirdik (~890 MB).

Q: 20 evden niye sadece 3'unu kullandik?

İki neden: 1. **Pratik**: 20 evin hepsini çalışmak ARIMA rolling forecast ile bilgisayarımızda saatler sürer 2. **Yeterli**: Hocanın "tek hane mi çalıştınız?" eleştirisine cevap vermek için 3 ev yeterli. Sonuç 3 evde de aynı olursa "tek hane tesaduf değil" demis oluyoruz

Sectigimiz evler: - **Ev 1**: 372 W ortalama, dondurucu/dryer ağırlıklı - **Ev 2**: 434 W ortalama, "tipik" İngiliz evi (referans) - **Ev 5**: 673 W ortalama, daha ağır tüketim

Yani farklı profiller. Eğer ARIMA üç evde de kazanıyorsa, ev tipinden bağımsız.

Q: 8 saniyelik veriyle nasıl yarını tahmin ediyorsun? Çok detaylı değil mi?

İyi soru. Ham veriyle çalışmadık. **Özetledik**:

1. 8 saniye veri (yaklaşık 5.7 milyon satır Ev 2 için)
2. **Gunluk ortalama**ya indirdik → 5.7M satır → ~630 gün
3. **7 günlük hareketli ortalama** uyguladık → gürültü silindi, haftalık doğu kaldı
4. **80% eğitim, %20 test** olarak boldık

"Günlük ortalama" demek: o gün boyunca evin çektiği ortalama wattaj. Örneğin 24 saat boyunca ortalama 280 W çekmiş. Bu sayı modellerin tahmin ettiği şey.

Q: Niye günlük? Saatlik daha iyi olmaz mıydı?

Saatlik denedik (iterasyon 1), $R^2 = -0.13$ çıktı. Negatif demek "modelimiz ortalama tahminden bile daha kötü" demek. Yani saatlik veride gürültü çok fazla, modeller karman corman tahmin yapıyor.

Günlük ortalama gürültüyü azaltıyor, modelin yakalayabileceği pattern'i ortaya çıkarıyor. Bu **iterasyon hikayemizin** kalbi.

BOLUM 3: Tahmin Probleminin Temeli

Q: "Zaman serisi tahmini" tam olarak nedir?

Bir sayının zamanla nasıl değiştiğini gösteren veri = zaman serisi. Örnekler: - Borsa fiyatı (her saniye değişir) - Hava sıcaklığı (her saat değişir) - Senin elektrik tüketimin (her gün değişir)

Tahmin = "şu anki ve geçmiş değerleri kullanarak gelecekteki değeri bil." Klasik problem, 100 yıldır üzerine çalışılıyor.

Q: Niye zor? Veri var, sayılara bak yap gitsin?

Çünkü **veri rastgele değil ama tahmin edilebilir de değil**. İki dengede: - **Çok kalıplı olsa**: "Yarın = bugün" der geçersin - **Çok rastgele olsa**: Tahmin imkansızdır

Gerçek hayat ortada. Örneğin senin tüketimin: - Mevsim etkisi var (kış > yaz) ← tahmin edilebilir - Hafta sonu etkisi var (cumartesi > salı) ← tahmin edilebilir - Belirli saatlerde pik (18:00 yemek) ← tahmin edilebilir - Bugün bir misafir geldi 2 saat extra TV ← rastgele

Model bu **tahmin edilebilir kalibi öğrenmeye** çalışıyor. Rastgele kısmi değil.

BOLUM 4: Modeller

Burayı dikkatli oku, hocanın **en çok soru sorabileceği yer** burası.

Q: 4 modelimiz vardı. Tam olarak ne yapıyorlar?

Sirasi önemli. **Basitten karmasiga:**

1. Persistence (Yapışkanlık) Kural: “Yarınki tüketim = bugunku tüketim.”

Tek satırlık kod:

```
tahmin[yarin] = gercek[bugun]
```

Yani hiçbir “öğrenme” yok. Sadece son bilineni tekrar et. Buna **baseline** denir, kontrolcuye benzer. Karmasik modellerin gerçekten faydalı olup olmadigini test etmek için.

Niye ekledik? Cunku **eger karmasik modelin Persistence’i yenemiyorsa, o model ise yaramaz.** Bu projenin **en kritik bulgusu** buradan cikiyor.

2. ARIMA (Klasik istatistik) Tam adi: AutoRegressive Integrated Moving Average

Mantigi: “Bugunku deger, son birkac gunun degerlerinin agirlikli ortalamasi + son birkac gun yaptiqi hatalarin agirlikli ortalamasidir.”

Matematiksel olarak:

$$y[t] = c + a \cdot y[t-1] + a \cdot y[t-2] + e[t] + b \cdot e[t-1] + b \cdot e[t-2]$$

burada: $-y[t-1]$ = dunku deger $-y[t-2]$ = onceki gunun degeri $-e[t-1]$ = dun yaptiqimiz tahmin hatasi $-a, b$ katsayilari → bunlari veriden öğreniyoruz

Bizimkisi **ARIMA(2, 1, 2)** = 2 önceki deger + 1 fark + 2 hata terimi.

Niye 1 fark? Cunku veri “durağan” degildi. Veriyi yarmak/farkini almak gerekti.

Niye en iyi sonucu verdi? Cunku **gunluk tüketimde bugün-dün ilişkisi çok guclu** (lag-1 otokorelasyon yuksek). ARIMA bunu dogrudan kullanıyor.

3. LSTM (Derin öğrenme) Tam adi: Long Short-Term Memory

Mantigi: Bir tür sinir ağı (neural network). Kelimeyle anlatmak zor ama soyle:

Hayal et: bir adam masada oturuyor, onunde son 14 gunun guc degerleri yazili. Bu adamin bir “hafizasi” var. 14 gunu okuduktan sonra 15. gunu tahmin ediyor.

LSTM’in ozelligi: Bu hafizada hangi gunun önemli olduğunu **otomatik öğreniyor**. Örneğin “8. gun pazardı, pazarlar önemli, oraya odaklan” diyebiliyor.

Bizimkisi 3 katman (128 → 64 → 32 nokta). Toplam **128.929 parametre** öğreniyor.

Niye bu kadar zayıf sonuc verdi? - 490 gün eğitim verisi, 129 bin parametre için **cok az** - Derin öğrenme tipik olarak milyonlarca veri ister - Gasparin ve diğeri (2024) aynı sonucu bulmuş: az veride basit baseline’lar derin öğrenmeyi yener

Cevap olarak: “LSTM kotu” demiyoruz. “Bu kadar az veride LSTM ise yaramiyor” diyoruz.

4. FB-Prophet (Facebook Prophet) Mantigi: Veriyi 3 parçaya böler: - **Trend**: Uzun vadeli yön (yaz düşüşü, kış çıkışı) - **Mevsimsellik**: Tekrarlı desenler (haftalık, yıllık) - **Tatil / özel olaylar**: Yılbaşı, bayram gibi

Sonra her parçayı ayrı ayrı model alır, toplar.

Niye en kötü sonucu verdi? 1. **Protokol farkı**: Prophet tüm 122 günlük test ufkunu tek seferde tahmin ediyor. Yanlış tahmin yaparsa ufuk boyunca hata birikiyor. ARIMA ve LSTM ise her gün dönün gerçek değerini görebiliyor (sonra detaylı açıklayacağım). 2. **Veri tipi**: Prophet uzun vadeli mevsimsel trend için tasarlanmış. Bizim veride dominant sinyal “yarın = bugün” otokorelasyonu, Prophet bunu hedeflemiyor.

Q: Yani 4 modelden hangisi en iyiydi?

Test seti R^2 değerleri (Ev 2):

Model	R^2
Persistence	0.873
ARIMA	0.876 en yüksek
LSTM	0.748
Prophet	0.015

ARIMA rakamlar olarak kazandı ama Persistence ile farkı sadece 0.003. Bu farkın istatistiksel olarak anlamlı olup olmadığı sonraki sorunun konusu.

BÖLÜM 5: Metrikler

Q: R^2 (R-kare) ne demek?

0 ile 1 arasında bir sayı. Anlamı: - $R^2 = 1.0$: Model mükemmel, hiçbir hata yapmamış - $R^2 = 0.876$: Model verinin %87.6’sını açıklayabiliyor (yani büyük ölçüde doğru) - $R^2 = 0$: Model ortalama tahminden iyi değil - $R^2 < 0$: Model ortalama tahminden bile daha kötü (çok kötü)

Özet: Yüksek R^2 = iyi tahmin.

Q: RMSE, MAE, MSE ne?

Hepsi “tahmin ne kadar yanlış” diyen metrikler. Fark birim ve davranışa bağlı.

- **MSE (Mean Squared Error)**: Hataların karelerinin ortalaması. Birim “ W^2 ” (anlamsız).
- **RMSE**: MSE’nin karekökü. Birim **Watt**. ARIMA RMSE = 48.7 W = “ortalama tahminim 48.7 W yanlıtıcı.”
- **MAE (Mean Absolute Error)**: Hataların mutlak değerlerinin ortalaması. Yine Watt biriminde, daha az “uçtan etkilenir.”

Hepsi **düşük olunca iyi**.

Q: ARIMA RMSE = 48.7 W neye yarıyor?

Ev 2’nin ortalama günlük tüketimi **434.8 W**. Yani: - Hata = 48.7 W - Bu, ortalamanın **%11.2’si** kadar sapma - Günlük enerji cinsine çevirsek: $48.7 \text{ W} \times 24 \text{ saat} / 1000 = 1.17 \text{ kWh/gün hata}$ - UK elektrik fiyatı $\sim 0.27 \text{ GBP/kWh}$ ise: **$\sim 0.32 \text{ GBP/gün yanlış}$** = ayda $\sim 10 \text{ GBP}$

Yani modelimiz fena değil, ama mükemmel de değil.

BOLUM 6: En Kritik Konu - Rolling vs Multi-step Protokol

Bu kısmi anlarsan **hocayı etkilersin**.

Q: Rolling forecast ile multi-step forecast ne fark?

İki yaklaşımlar var:

Rolling (yuvarlanan) tek-adım önde: - Diyelim ki 122 günlük test setin var. - Gün 1'i tahmin etmeden önce: eğitim verisinin tamamını gör, tahmin et. - Gün 1'in **gerçek** değerini öğren (çünkü gerçek hayatta dün olduktan sonra bunu biliyorsun). - Gün 2'yi tahmin etmeden önce: eğitim verisi + gün 1 dahil tüm geçmişini gör, tahmin et. - Gün 3 öncesi: eğitim + gün 1 + gün 2 gerçekleri ile yeniden tahmin yap. - Böyle 122 gün boyunca.

Yani **her gün, en yeni gerçek veriyi görerek tahmin ediyorsun**. Bunun adı **teacher forcing** (öğretmen zorlaması). Persistence, ARIMA ve LSTM bu protokol altında çalışıyor.

Multi-step (çok adımlı): - Eğitim verisini bir kerede görüyorsun. - 122 günün tamamını **tek seferde** tahmin ediyorsun. - Hiçbir günün gerçek değerine erişemiyorsun. - Yanlış tahmin yaparsan ufuk boyunca hata birikiyor.

Prophet bu protokol altında çalışıyor.

Q: Niye bunları aynı protokole geri karşılaştırmadık?

İki sebep: 1. **Prophet'i rolling protokolde çalıştırmak çok pahalı**. Her test günü için Prophet'i baştan eğitmek gerekir, ~120 kat hesaplama maliyeti. 2. **Pratikte zaten Prophet böyle kullanılır**. Multi-step Prophet'in kanonik kullanımı.

Ama bu Prophet'a haksızlık diyenler doğru. Raporda bunu **acıkça yazıyoruz**: "Prophet skor olarak en kötü ama bunun bir kısmı protokolden kaynaklanıyor."

Q: Hocanın "Prophet niye bu kadar düşük?" sorusu gelirse?

Su cümleyi kafanda hazır tut:

"Prophet, 122 günlük test ufkunun tamamını tek seferde tahmin ediyor ve test seti gerçek değerlerine erişemiyor. ARIMA ve LSTM ise her gün bir önceki günün gerçek değerini görebiliyor (rolling protokol). Bu yapısal fark Prophet'in skorunu düşürüyor. Adil bir kıyaslama için Prophet'i da rolling modda çalıştırmak gerekir, ancak hesaplama maliyeti yaklaşık 100 kat artıyor."

BOLUM 7: İstatistiksel Anlamlılık (Diebold-Mariano)

Q: ARIMA $R^2=0.876$, Persistence $R^2=0.873$. Farkı 0.003. Bu gerçekten bir fark mı yoksa tesaduf mu?

Bunu cevaplamak için **istatistiksel test** lazım. Bizim kullandığımız: **Diebold-Mariano testi**.

Q: Diebold-Mariano testi nasıl çalışır?

Kısaca: "İki modelin tahminleri arasındaki farkın sıfırda olup olmadığını" test eder. Yani: "Bir modelin diğerinden gerçekten daha az hata yapıp yapmadığı" sorusuna cevap verir.

Çıktı: Bir DM istatistiği (sayı) ve bir **p-value** (0 ile 1 arası).

P-value: Eğer gerçekten iki model eşit performans gösteriyor olsaydı, gözlemlediğimiz farkı rastlantı eseri görmemizin olasılığı.

- **p < 0.05:** Fark anlamlı. Modeller gerçekten farklı.
- **p > 0.05:** Fark anlamsız. Gözlemladığımız fark muhtemelen tesadüf.
- **p < 0.001:** Çok çok anlamlı, “kesinlikle farklı” gibi.

Q: Bizim sonuçlarımız?

Karsılaştırma	DM	p	Sonuç
ARIMA vs Persistence	-0.43	0.665	Anlamsız! ARIMA aslında Persistence’i yenmiyor.
LSTM vs Persistence	+3.94	<0.001	Persistence anlamlı olarak iyi
Prophet vs Persistence	+7.95	<0.001	Persistence anlamlı olarak iyi
ARIMA vs LSTM	-3.77	<0.001	ARIMA anlamlı olarak iyi
ARIMA vs Prophet	-7.96	<0.001	ARIMA anlamlı olarak iyi

Q: Bunlar ne anlama geliyor?

Bence projemizin en değerli buluşu:

1. **ARIMA “kazandı” gibi görünüyor ama istatistiksel olarak Persistence ile esdeğer.** Yani bu kadar veriye ve hesaplama gücüne ARIMA için gerek yok, tek satırlık kural aynı işi yapar.
2. **LSTM ve Prophet, tek satırlık kuraldan istatistiksel olarak DAHA KOTU.** Yani derin öğrenme veya Prophet eklemek, hiçbir şey eklemekten daha zararlı.
3. **ARIMA, LSTM ve Prophet’a karşı anlamlı olarak iyi.** Yani seçenek bunlar arasındaysa ARIMA al, ama tek satırlık kural daha iyi.

Bu bulgu **akademik olarak değerli** çünkü honest. Çoğu çalışmayı “ARIMA en iyi” derken yayınlıyorlar, ama Persistence ile kıyaslamıyorlar. Biz kıyasladık.

Q: Hocanın “DM testi nedir, ne yapıyor?” sorusu gelirse?

Kısa cevap:

“Diebold-Mariano, iki modelin tahmin hatalarının istatistiksel olarak farklı olup olmadığını test eden bir hipotez testidir. Negatif DM istatistiği ilk modelin daha az hata yaptığını gösterir. P-value 0.05’in altında olursa fark anlamlıdır. Bizim ARIMA-Persistence p-değerimiz 0.665, yani fark anlamsız; ARIMA pratik olarak Persistence’i yenmiyor.”

BOLUM 8: Cross-House Validation

Q: Niye 3 evde de çalıştı?

“Tek evde bulgu” diye eleştirilirse diye. Eğer ARIMA sadece Ev 2’de iyi olsa, şans olabilirdi. 3 evde de aynı patern göruluyorsa, **genel bir gerçek**.

Q: Sonuçlar?

Model	Ev 1 R ²	Ev 2 R ²	Ev 5 R ²
Persistence	0.963	0.873	0.901
ARIMA	0.976	0.876	0.905
LSTM	0.859	0.748	0.647
Prophet	-2.315	0.015	-1.186

3 evde de: - ARIMA en yuksek (ama hep Persistence'a cok yakin) - LSTM ortada - Prophet en alt (Ev 1 ve Ev 5'te NEGATIF, yani ortalamadan kotu)

Bu siralama tutarsiz olsa endiselenirdik. Tutarli oldugu icin guvenimiz artti.

Q: Prophet'in Ev 1'de R² = -2.3 olmasi ne demek?

Modelin urettigi tahminler test setinin **kosulsuz ortalamasindan** bile daha kotu. Yani test gunlerinin ortalamasini hesaplayip her gunu o sayi ile tahmin etsek, Prophet'tan daha iyi sonuc alirdik. Ozellikle Ev 1'in mevsimsellik desenini Prophet yanlis ogrenmis.

BOLUM 9: Uretim Surecimiz

Q: Pipeline'i nasil kurduk, sirayla anlat.

1. **Veri indirme:** Kaggle'dan UK Electrical Load (REFIT mirror) indirdik. 886 MB ZIP. Icinden Ev 2'yi cikardik.
2. **Veri okuma:** pandas ile House_2.csv'yi yukledik. 5.7 milyon satir, kolonlar Time, Aggregate, Appliance1..9.
3. **Aykiri deger temizleme:** Negatif okumalari sildik (klemp polaritesi hatalari). Ust %1'i sildik (sensor hatasi).
4. **Yeniden ornekleme:** 8-saniye veriyi gunluk ortalamaya cevirdik. ~5.7M satir → ~630 satir.
5. **Yumusatma:** 7 gunluk hareketli ortalama uyguladik. Haftalik desen kaldi, gunluk gurultu silindi.
6. **Eksik veri:** Forward-fill + backward-fill.
7. **Egitim/Test bolme:** Ilk %80 (yaklasik 490 gun) egitim, son %20 (yaklasik 122 gun) test.
8. **Model 1 - Persistence:** `predictions[i] = test[i-1]`. Bir satir kod.
9. **Model 2 - ARIMA:**
 - ADF testi ile veri duraganligini olc → $p=0.94$, duraganlik yok, $d=1$ fark al
 - Grid search: p in $[0,2]$, q in $[0,2]$, AIC'ye gore en iyi → ARIMA(2,1,2), AIC=4547.6
 - Her test gunu icin: modeli yeniden uydur, 1 gun tahmin yap
10. **Model 3 - LSTM:**
 - Min-Max ile veriyi 0-1 arasina olceklendir
 - 14 gunluk pencereler olustur
 - Adam optimizer, MSE loss, 100 epoch, batch=16, early stopping
 - Seed=42
11. **Model 4 - Prophet:**
 - Veriyi 'ds' (tarih) ve 'y' (deger) kolonlarına çevir
 - Haftalik + yillik mevsimsellik aktif, multiplicative mod
 - 122 gun tek seferde tahmin

12. **Degerlendirme:** Her model icin MSE, RMSE, MAE, R^2 hesapla.
13. **DM testi:** Tum ikili karsilastirmalar icin DM istatistigi + p-value.
14. **Cross-house:** Ev 1 ve Ev 5'i de cikar, ayni pipeline'i calistir.
15. **Gorseller:** 12 PNG (EDA, pipeline diyagrami, LSTM mimarisi, model karsilastirma, metrikler, DM, cross-house, vs.)
16. **Belgeler:** Rapor (EN + TR PDF), sunum (PPTX), README.

Q: Iterasyonlarimiz?

3 iterasyon vardi.

Iter 1: Saatlik resample + 3 aylık veri. - ARIMA $R^2 = -0.13$, LSTM = 0.09, Prophet = -0.17. - Gorudugun gibi negatif. Veri çok az, gürültü çok yüksek.

Iter 2: Günlük resample + tüm veri + tek seferlik ARIMA forecast. - ARIMA $R^2 = 0.08$, LSTM = -0.03, Prophet = 0.03. - Ufak ilerleme. ARIMA hala kötü çünkü 122 günü tek seferde tahmin etmeye çalışıyor.

Iter 3 (final): Günlük + 7-gün yumuslatma + ARIMA rolling forecast. - ARIMA $R^2 = 0.876$, LSTM = 0.748, Prophet = 0.015. - En büyük sıçrama, rolling forecast'a geçisten geldi.

Bu süreç rapor ve sunumda ayrı bir bölüm (Şekil 10).

BOLUM 10: Hocanın Soracağı Sorular ve Cevapları

Q: "Persistence baseline neden eklediniz?"

"Akademik olarak iyi pratik. Karmaşık modelin gerçekten değerli olup olmadığını göstermek için trivial baseline gerekli. Gasparin ve diğerleri (2024) gibi son dönem makaleleri bunu vurguluyor."

Q: "ARIMA $R^2=0.876$ çok yüksek görünüyor, kuskulu değil mi?"

"Yüksek görünüyor çünkü biz veriyi 7-gün yumusattık ve rolling forecast kullandık. Her tahminden önce dünyanın gerçek değerini görmesine izin verdik (teacher forcing). Bu, gerçek hayatta üretim ortamında oluşan duruma denk geliyor."

Q: "Niye sadece 3 hane?"

"Hesaplama maliyeti. Her hane için ARIMA rolling forecast'ı 10-15 dakika sürüyor; 20 hane = 5+ saat. Ucu küçük ama temsil eden bir örnektir. Gelecek çalışmalar tüm 20 haneyi kapsayabilir."

Q: "Hava verisi ya da takvim özellikleri eklediniz mi?"

"Hayır, tek değişkenli kurulum tercih ettik. Bunun nedeni adil karşılaştırma yapmak. Egzojen özellikler ekleyince LSTM daha çok faydalanır (çok değişkenli yapıdan). Sonraki çalışmada SARIMAX ve multivariate LSTM denenebilir."

Q: "Niye günlük? Saatlik veya 15-dakikalık tahmin daha pratik olmaz mıydı?"

"Saatlikte gürültü çok yüksek, sonuçlar negatif R^2 verdi. Günlük en istikrarlı sonucu üretti. Pratik olarak günlük-önceki dengesizlik fiyatlandırması için kullanılabilir. Saatlik için daha büyük veri seti gerekir."

Q: “Sonucta hangi modeli kullanalim?”

“Bizim verimizde Persistence yeterli. ARIMA biraz daha iyi gorunuyor ama istatistiksel olarak fark anlamlı degil. LSTM ve Prophet bu veri olcegi icin uygun degil. Eger ham daha yuksek frekansli veri varsa veya egzojen degiskenler eklemek mumkunse derin ogrenme tekrar gundeme gelir.”

Q: “Neden Calibri font kullandiniz?”

“Okunaklılık. Cogu ITU sablonu Times New Roman onerir ama Calibri sans-serif olarak ekran ve baski okumalarında daha temizdir. Hocanın acik bir font kisitlamasi olmadigi icin Calibri’yi tercih ettik.”

Q: “Sunum kac dakika surecek?”

“10-15 dakika hedefliyoruz. 18 slayt. Slayt basi ortalama 45 saniye. Sorulara 5-10 dakika ayrilabilir.”

BOLUM 11: Konsantre Notlar (Sunum Sirasinda)

- **Slayt 7 (Persistence):** “Karmasik modelin degerini ispatlamak icin trivial baseline ekledik.”
 - **Slayt 10 (Rolling vs Multi-step):** “ARIMA ve LSTM dunun gercek degerini her tahminden once gorebiliyor. Prophet ise tek seferde 122 gunluk ufku taahhut ediyor.”
 - **Slayt 14 (DM testi):** “ARIMA, Persistence’i istatistiksel olarak yenmiyor ($p=0.665$).”
 - **Slayt 15 (Cross-house):** “Siralama uc evde de tutarli, bulgu sans degil.”
 - **Slayt 17 (Discussion):** “ARIMA kazandi ama Persistence ile esdeger. Lag-1 otokorelasyon her seyi yapiyor.”
-

BOLUM 12: Eger Konuyu Hala Anlamadiysan

Su uc sey kafana yerlessin yeter:

1. **“Yarin = bugun” kurali (Persistence) cok guclu cikti.** Hicbir model bunu istatistiksel olarak yenemedi.
2. **ARIMA “kazandi” ama “kazanc” istatistiksel olarak sifir.** Sayi kaginda $0.876 > 0.873$, ama testler bunun anlamsiz oldugunu soyluyor.
3. **LSTM ve Prophet zayif, ama bunun nedeni modellerin kotu olmasi degil.** LSTM icin yetersiz veri, Prophet icin yapisal protokol farki suclu.

Ucunden bir tanesini sorulduqunda anlatabilirsen sunumda hicbir problem yasamazsin.

BOLUM 13: Sunum Onunde Bir Saat Once

- **5 dakika sunum gozat:** Hangi slaytta hangi gorsel oldugunu hatirla
 - **3 dakika DM testi tekrar:** P-value nedir, ne anlama gelir
 - **2 dakika Persistence anlat:** Kendi kelimelerinle “yarin = bugun” kuralinin neyi yaptigini
 - **1 dakika nefes:** Gerek yok endiseye, projeniz iyi.
-

Sorularin olursa whatsapp’tan yaz. Yoksa iyi sunumlar.

Iyi calismalar!